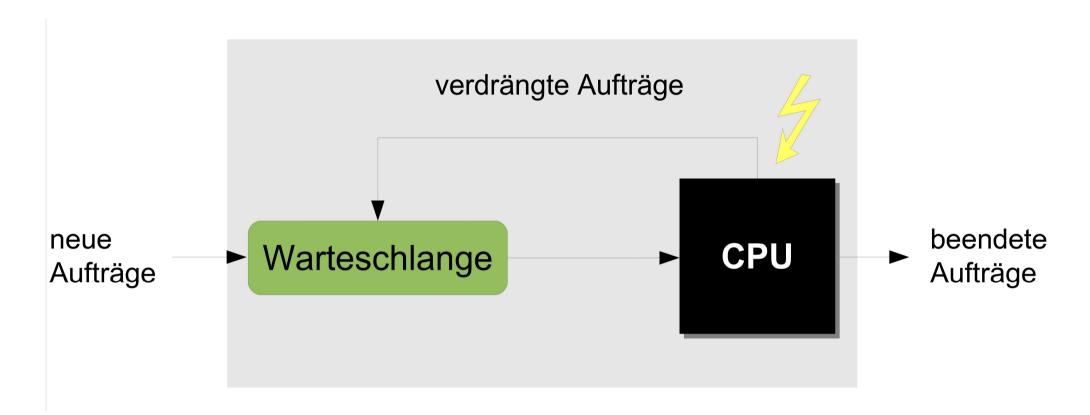
- Sorgt für den geordneten Ablauf konkurrierender Prozesse
- Grundsätzliche Fragestellungen
 - o Welche Arten von Ereignissen führen zur Verdrängung?
 - o In welcher Reihenfolge sollen Prozesse ablaufen?
- Wichtig eher für Großrechner / Server
 - o viele rechenbereite Prozesse
 - o Mischung aus Stapel- und TimeSharing-Betrieb
- Ziele einer Schedulingstrategie (scheduling algorithm)
 - o benutzerorientiert, z.B. kurze Antwortzeiten
 - o systemorientiert, z.B. optimale CPU-Auslastung
- Keine Schedulingstrategie kann alle Bedürfnisse erfüllen.



Scheduling



Ein einzelner Scheduling-Algorithmus charakterisiert sich durch die Reihenfolge von Prozessen in der Warteschlange und die Bedingungen, unter denen die Prozesse der Warteschlange zugeführt werden.



Was passiert bei einem Taskwechsel?

- Wechsel vom Benutzer- in den Kernel-Modus
- Sicherung des Zustands des laufenden Prozesses
 - o Akku
 - o Register
 - o Speicherzuordnungstabelle
- Auswahl eines neuen Prozesses
- Laden der neuen Speicherzuordnungstabelle
- Start des Prozesses
- Cache neu laden

? Anzahl Taskwechsel/Kontextwechsel unter Windows:



Prozessverhalten

- CPU-intensive Prozesse
 - o lang anhaltender Bedarf an Rechnungen
- E/A-intensive Prozesse
 - o nur kurze Berechnungen, häufige (evtl. auch kurze) E/A

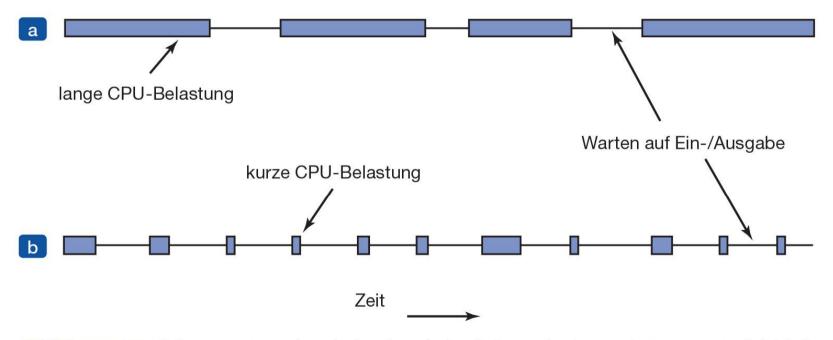


Abbildung 2.39: Häufung von CPU-Gebrauch alternierend mit Zeiträumen, in denen auf E/A gewartet wird: (a) ein CPU-intensiver Prozess; (b) ein E/A-intensiver Prozess.



Ziele von Schedulingstrategien

Alle Systeme

- o Fairness jeder Prozess bekommt einen fairen Anteil an Rechenzeit
- o Policy Enforcement vorgegeben Strategien werden durchgesetzt
- o Balance alle Teile des Systems sind ausgelastet
- Stapelverarbeitungssysteme
 - o Durchsatz Maximierung der Jobs pro Stunde
 - o Durchlaufzeit Minimale Zeit vom Start bis Ende
 - o CPU-Auslastung
- Interaktive Systeme
 - o Antwortzeit schnelle Reaktion des Systems
 - o Proportionalität Erwartungen des Benutzers erfüllen
- Echtzeitsysteme
 - o Deadlines einhalten Datenverlust vermeiden
 - Vorhersagbarkeit Qualitätseinbußen in Multimediasystemen vermeiden

Scheduling Stapelverarbeitungssystemen

- First-Come-First-Served-Scheduling
- Shortest-Job-First-Scheduling
- Shortest-Remaining-Time-Next-Scheduling



First-Come-First-Served-Scheduling

- Rechenbereite Prozesse werden in eine Warteschlange eingeordnet und gemäß ihrer Ankunftszeit von der CPU abgearbeitet
- Blockiert ein Prozess, dann kommt der nächste Prozess an die Reihe.
- Wird der blockierte Prozess wieder rechenbereit, wird er neu am Ende der Warteschlange einsortiert (kooperativ)
- Vorteile
 - o einfach
 - keine Unterbrechung von Prozessen durch Scheduler (Selbstaufgabe)
- Nachteil
 - o hohe Durchlaufzeit von E/A-intensiven Prozessen

Shortest-Job-First-Scheduling



Abbildung 2.41: Ein Beispiel für Shortest-Job-First-Scheduling: (a) Ablauf der vier Jobs in der Originalfolge. (b) Ablauf in der Shortest-Job-First-Reihenfolge.

Durchschnitt der Laufzeit im Fall a:

$$(8 + 8+4 + 8+4+4 + 8+4+4+4) / 4 = 14$$

Durchschnitt der Laufzeit im Fall b:

$$(4 + 4+4 + 4+4+4 + 4+4+4+8) / 4 = 11$$



Shortest-Job-First-Scheduling

- Einsatz in der Stapelverarbeitung
- Laufzeit muss bekannt sein, bzw. abgeschätzt werden können
- Die bereiten Prozesse werden gemäß ihrer Laufzeit in der Warteschlange sortiert und abgearbeitet (kooperativ)
- Vorteile
 - o einfach
 - keine Unterbrechung von Prozessen durch Scheduler (Selbstaufgabe)
- Nachteil
 - o Laufzeit muss bekannt sein
 - o Prozesse müssen verfügbar sein



Shortest-Remaining-Time-Next-Scheduling

- unterbrechende Version von Shortest Job First
- Scheduler wählt immer den Prozess aus, dessen verbleibende Zeit am kürzesten ist.
- Sobald ein neuer Job ankommt, wird dessen gesamte Laufzeit mit der verbleibenden Zeit des aktuellen Prozesses verglichen.
- Benötigt neue Prozess weniger Zeit -> stopp und neue Prozess beginnt.
- Dieses Modell ist f
 ür neue, kurze Jobs sehr g
 ünstig.



Scheduling interaktive Systeme

- Round-Robin-Scheduling
- Prioritätsscheduling
- Multi-Level Feedback Scheduling
- shortest-Process-Next-Scheduling
- Garantiertes Scheduling (Guaranteed Scheduling)
- Fair-Share-Scheduling



Round-Robin-Scheduling

- Jeder bereite Prozess darf gewisse Zeit Q (Quantum) laufen
 - o Läuft am Ende von Q Prozess immer noch, wird unterbrochen.
 - -> danach an das Ende der Warteschlange
 - o Vorzeitige Blockade oder Beendigung -> sofortige Weitergabe
- Präemptives Verfahren
- Zeitscheibe: feste Zeit Z, typische Werte für Z: 10-100 ms
- Vorzeitiger Prozessorentzug durch Blockierung oder Terminierung des Prozesses möglich

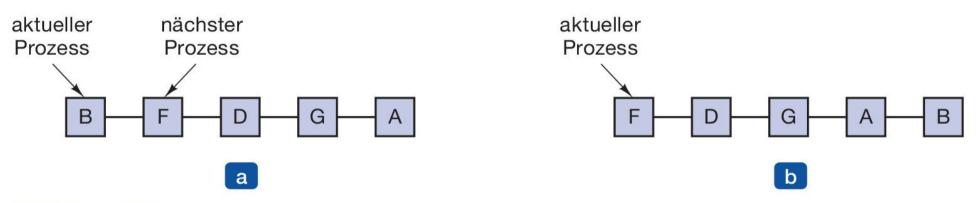
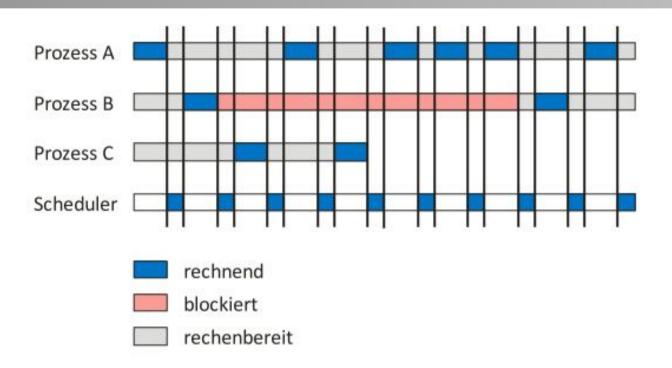


Abbildung 2.42: Round-Robin-Scheduling: (a) Liste der lauffähigen Prozesse; (b) Liste der lauffähigen Prozesse, nachdem *B* sein Quantum aufgebraucht hat.

Round-Robin-Scheduling Beispiel



Problem

- o kritische Einstellung der Zeitspanne, die ein Prozess rechnen darf
 - hoher Wert: hohe Antwortzeiten, wenig Kontextwechsel
 - niedriger Wert: kurze Antwortzeit, viele Kontextwechsel
- o Prozesse müssen präemptiv sein

- Jedem Prozess wird eine Priorität (Wichtigkeitsstufe) durch den Anwender oder ein gesondertes Verfahren zugeordnet.
- Laufen wird nun stets der oder die bereiten Prozesse mit der höchsten Priorität;
- laufende Prozesse mit geringerer Priorität werden verdrängt.
 Bei gleicher Prioritätsstufe wird meist Round-Robin oder FCFS angewendet.
- Prioritäten können
 - o statisch oder
 - o dynamisch vergeben werden

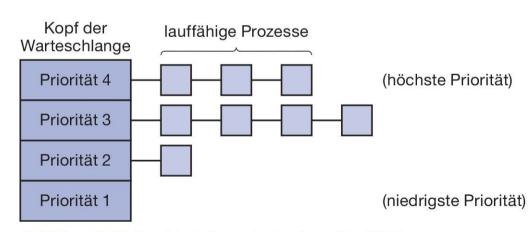


Abbildung 2.43: Eine Schedulingstrategie mit vier Prioritätsklassen.

- Mögliches Problem:
 - o Starvation Verhungern (ein Prozess wird nie ausgewählt)
- Die Umsetzung erfolgt mit
 - o mehreren Ready Queues für unterschiedliche Prioritäten (wenig Prioritäten)
 - o geordneter Ready Queue (sonst)
- Wichtig
- E/A-intensive Prozesse, sollten schnell Rechenzeit bekommen
 - o wenig Blockierung der E/A-Ressourcen
 - o halten bei der nächsten E/A-Operation wieder an



Multi-Level Feedback Scheduling

- Ein Prozess wird abhängig von seiner bisherigen Laufzeit priorisiert.
- Wird ein Prozess neu erzeugt, dann erhält er die höchste Priorität.
- Wenn dieser Prozess das erste Mal beendet wird, dann wird auch seine Priorität schrittweise herabgestuft.
- Präemptiv mit festem Zeitintervall
- Mögliches Problem ist Starvation, wenn häufig neue Prozesse eintreten
- Lösung
 - o Größere Zeitintervalle, je niedriger die Priorität
 - o Prozess allmählich wieder hoch priorisieren

Shortest-Process-Next-Scheduling

- Shortest-Job-First-Strategie f
 ür interaktive Prozesse
- Schema: auf Befehl warten - Befehl ausführen - auf Befehl warten -Befehl ausführen ...
- Befehl entspricht Job, somit Antwortzeit minimieren durch kürzesten zuerst.
- Problem: Abschätzen der Laufzeit der Befehle
- Ansatz: Historischer Verlauf der Befehle gleitender Mittelwert, gewichteter Mittelwert...

Garantiertes Scheduling (Guaranteed Scheduling)

- Versprechungen bezüglich der Geschwindigkeiten machen und einhalten
 - o Bsp.: Wenn n Benutzer eingeloggt sind, bekommt jeder etwa 1/n der CPU-Leistung
 - o Ähnlich auf einem Einbenutzersystem mit n laufenden Prozessen
- Nachverfolgen der zugewiesenen CPU-Zeit zur verbrauchten

- Bisherige Betrachtung unabhängig von Nutzer
 - o Startet Benutzer 1 neun Prozesse und Benutzer 2 einen Prozess, bekommt Benutzer 1 90% der CPU-Zeit und Benutzer 2 10%.
- Nach Fair-Share belegt jeder Benutzer gleiche CPU-Zeit (hier 50%) unabhängig von Anzahl der Prozesse

Vergleich der Scheduling-Verfahren

Prozesse

Prozess	Ankunftszeit	Laufzeit
А	0	3
В	2	6
С	4	4
D	6	5
E	8	2

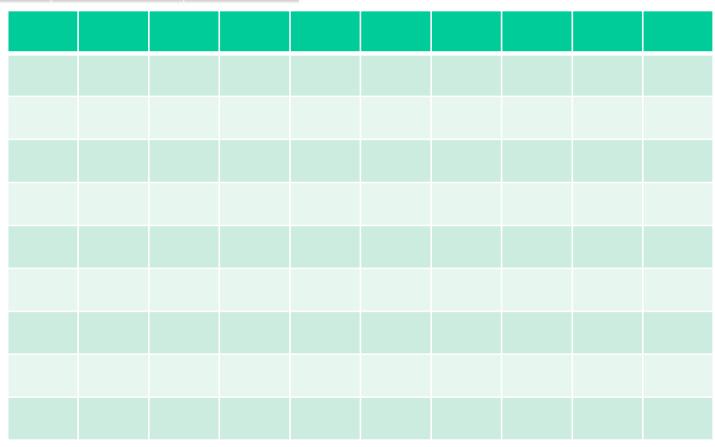
In welcher Reihenfolge werden die Prozesse bei folgenden Scheduling-verfahren ausgeführt und nach welcher Laufzeit sind sie jeweils beendet?

- a) FCFS (First come first serve)
- b) SJF (Shortest job first)
- c) RR (Round Robin, timeslice = 1)



FCFS (First come first serve)

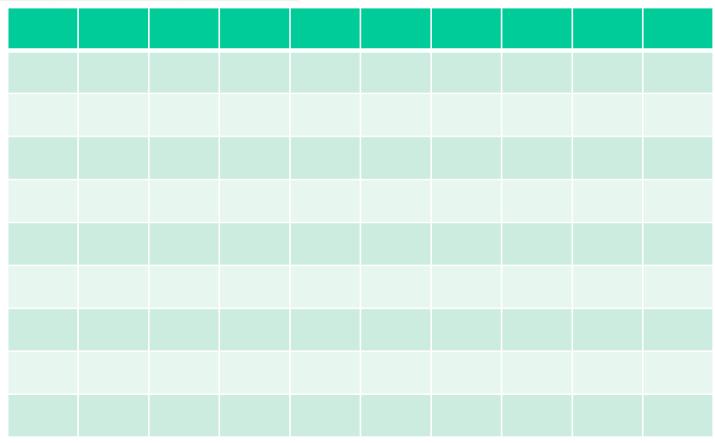
Prozess	Ankunftszeit	Laufzeit
Α	0	3
В	2	6
С	4	4
D	6	5
E	8	2





SJF (Shortest job first)

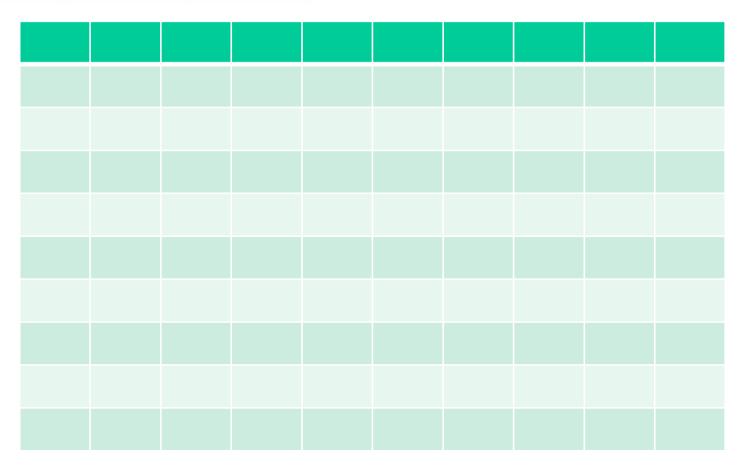
Prozess	Ankunftszeit	Laufzeit
А	0	3
В	2	6
С	4	4
D	6	5
E	8	2





RR (Round Robin, timeslice=1)

Prozess	Ankunftszeit	Laufzeit
Α	0	3
В	2	6
С	4	4
D	6	5
E	8	2





Scheduling Echtzeitsysteme

- harte Echtzeitsysteme
 - o absolute Deadline
- weiche Echtzeitsysteme
 - o Dealine, nicht einhalten unerwünscht aber tolerierbar.
- Echtzeitverhalten durch Unterteilung in vorhersehbare und vorher bekannte Ereignisse
 - o Prozesse allgemein kurzlebig.
 - D Weit weniger als einer Sekunde vollständig abarbeitbar.