



**Hochschule  
für Oekonomie & Management**  
University of Applied Sciences

**FOM Hochschule für Oekonomie & Management**

Hochschulzentrum Düsseldorf

**Bachelor-Thesis**

im Studiengang Wirtschaftsinformatik

zur Erlangung des Grades eines

Bachelor of Science (B.Sc.)

über das Thema

**Optimierung bestehender Workflow-Systeme durch kennzahlengestützte  
Analyse: Planung, Entwicklung und Evaluation einer Klassifikations- und  
Scoring-Pipeline mittels Natural Language Processing für Boutique-  
Personalberatungen**

von

Maximilian Brade

Erstgutachter: Prof. Dr. Rüdiger Buchkremer

Matrikelnummer: 729145

Abgabedatum: 23.06.2026

## Inhaltsverzeichnis

|                                                           |            |
|-----------------------------------------------------------|------------|
| <b>Abbildungsverzeichnis.....</b>                         | <b>III</b> |
| <b>Abkürzungsverzeichnis.....</b>                         | <b>IV</b>  |
| <b>Tabellenverzeichnis .....</b>                          | <b>V</b>   |
| <b>1. Einleitung .....</b>                                | <b>1</b>   |
| <b>2. Einführung in das Thema .....</b>                   | <b>3</b>   |
| <b>3. Forschungsfragen und Ziel der Arbeit .....</b>      | <b>6</b>   |
| <b>4. Methodik der Arbeit.....</b>                        | <b>8</b>   |
| <b>5. Vorläufige Gliederung der Bachelor-Thesis .....</b> | <b>14</b>  |
| <b>6. Ergebnis der Literaturrecherche .....</b>           | <b>16</b>  |
| <b>7. Vorläufige Zeitplanung.....</b>                     | <b>20</b>  |
| <b>8. Literaturverzeichnis .....</b>                      | <b>VI</b>  |

## Abbildungsverzeichnis

|                                                         |    |
|---------------------------------------------------------|----|
| Abbildung 1: Methodisches Vorgehen.....                 | 8  |
| Abbildung 2: Ausschnitt Literaturrecherche Teil 1 ..... | 11 |
| Abbildung 3: Ausschnitt Literaturrecherche Teil 2 ..... | 12 |
| Abbildung 4: Ausschnitt Literaturrecherche Teil 3 ..... | 12 |
| Abbildung 5: Ausschnitt Literaturrecherche Teil 4 ..... | 13 |
| Abbildung 6: Ausschnitt Literaturrecherche Teil 5 ..... | 13 |
| Abbildung 7: Zeitplan Bachelorarbeit .....              | 20 |

## Abkürzungsverzeichnis

|           |                                     |
|-----------|-------------------------------------|
| B2B ..... | <i>Buisness-to-Buisness-Akquise</i> |
| IT .....  | <i>Informationstechnik</i>          |
| LLM ..... | <i>Large Language Models</i>        |
| MRQ ..... | <i>Main Research Question</i>       |
| NLP ..... | <i>Natural Language Processing</i>  |
| RQ .....  | <i>Research Question</i>            |

## Tabellenverzeichnis

|                                                                  |    |
|------------------------------------------------------------------|----|
| Tabelle 1: Übersicht Suchalgorithmus .....                       | 10 |
| Tabelle 3: Vorläufige Gliederung der Bachelorthesis Teil 1 ..... | 14 |
| Tabelle 4: Vorläufige Gliederung der Bachelorthesis Teil 2 ..... | 15 |

# 1. Einleitung

Die Titelwahl soll den Untersuchungsgegenstand der Bachelor-Thesis präzise abbilden und den thematischen Rahmen der Ausarbeitung definieren. Während der initialen Themenfindung lag der Fokus zunächst breit auf der Automatisierung der vertrieblichen Stellenbeobachtung. In enger Abstimmung mit dem kooperierenden Unternehmen sowie den betreuenden Gutachtern wurde dieser Rahmen jedoch inhaltlich und prozessual stark präzisiert.

Das kooperierende Unternehmen agiert als sogenannte „Boutique“ ist eine hochspezialisierte Personalberatung, die exklusiv in einer fachlichen Nische (dem Kultursektor sowie der öffentlichen Hand) operiert. Aufgrund dieser Spezialisierung sind generische Massenslösungen unzureichend. Zudem dient das automatisierte Screening von Stellenbörsen in diesem Fall nicht dem klassischen Headhunting, sondern primär der vertrieblichen Marktanalyse und der Buisness-to-Buisness-Akquise (B2B).

Im Zentrum des unternehmerischen Interesses und damit auch im Fokus dieser Arbeit, steht die konkrete Planung, Entwicklung und Umsetzung eines funktionierenden Informationstechnik-Artefakts (IT). Ziel ist es, das bisherige, statische Power-Automate-Skript durch eine intelligente Daten-Pipeline abzulösen. Bei dem zu entwickelnden IT-Artefakt handelt es sich bewusst nicht um eine eigenständige, von Grund auf neu programmierte Softwareanwendung. Vielmehr liegt der Fokus im Sinne der Ressourceneffizienz auf einer prozessualen Systemintegration, bei der die Natural Language Processing-Modelle (NLP) in bestehende Workflow- und Business-Intelligence-Umgebungen, wie beispielsweise n8n oder Microsoft Power Automate implementiert und orchestriert werden. Dieser Basisprozess umfasst vier aufeinander aufbauende Schritte:

Erstens, den automatisierten Quellenabruf (Web Scraping), Zweitens die KI-gestützte Relevanzklassifikation zum Filtern unpassender Stellen, Drittens die semantische Dublettenerkennung sowie Viertens die abschließende Priorisierung durch ein lernbasiertes Scoring-Modell.

Um diese praxisorientierte Tool-Entwicklung methodisch abzubilden, wurden im Vorfeld verschiedene thematische Schwerpunkte in Betracht gezogen, die zu folgenden Titel-Alternativen führten:

- Fokus auf den Gesamtprozess: „Von der Datenextraktion zur Priorisierung: Ein KI-basierter Ansatz zur Automatisierung der vertrieblichen Stellenbeobachtung“
- Fokus auf Datenbereinigung und NLP: „Semantische Dublettenerkennung und Relevanzklassifikation: Optimierung des Web Scrapings von Stellenbörsen durch Natural Language Processing“
- Fokus auf die praktische Umsetzung: „Planung, Entwicklung und Evaluation eines NLP-gestützten Scoring-Tools zur Priorisierung von Vakanzen in spezialisierten Personalberatungen“

Neben der reinen Systemintegration liegt die primäre Forschungsfrage des Unternehmens jedoch in der fundierten Auswertung der wirtschaftlichen und technischen Skalierbarkeit der eingesetzten Sprachmodelle bei der Umsetzung dieses Tools. Der evaluative Schwerpunkt der Arbeit wird folglich auf den Ressourcenverbrauch, die Genauigkeit und die Leistungsfähigkeit verschiedener Architekturansätze gelegt.

## 2. Einführung in das Thema

Die zunehmende Digitalisierung des Rekrutierungswesens führt zu einer enormen Menge an online verfügbaren Arbeitsmarktdaten. Dies stellt B2B-Vertriebsteams und spezialisierte Personalberatungen vor die Herausforderung, aus dieser Datenfülle die vielversprechendsten Vakanzen (Leads) effizient zu identifizieren und zu priorisieren. Im operativen Geschäft erfolgt die Stellenbeobachtung und Datenextraktion häufig noch über statische, regelbasierte Systeme, die bei der semantischen Komplexität und der großen Menge an unstrukturierten Textdaten an ihre Grenzen stoßen.

Im B2B-Vertrieb ist die systematische Priorisierung von potenziellen Neukunden mithilfe von maschinellem Lernen ein zentraler Hebel, um die Konversionswahrscheinlichkeit zu erhöhen und zeitliche Vertriebsressourcen effizient einzusetzen.<sup>1</sup> In der spezialisierten Personalberatung stammen die primären Vertriebs-Leads traditionell aus dem "warmen Netzwerk" und bereits bestehenden Kontakten. Dennoch gewinnt die strategische Stellenbeobachtung an Bedeutung: Öffentlich ausgeschriebene Vakanzen dienen hierbei nicht der klassischen Kaltakquise, sondern primär der fundierten Marktanalyse. Sie bieten wertvolle Aufhänger, um potenzielle Kunden anlassbezogen zu kontaktieren und somit zielgerichtete Akquise-Potenziale jenseits des warmen Netzwerks zu erschließen.

Um aus dieser Masse an Marktdaten wertvolle und priorisierbare Leads für den Vertrieb zu generieren, ist eine strukturierte Datenaufbereitung erforderlich. Eine der größten operativen Herausforderungen bei dieser automatisierten Stellenbeobachtung ist jedoch die massive Präsenz von semantischen Dubletten. Da Vakanzen häufig parallel auf verschiedenen Job-Portalen geteilt oder von Aggregatoren leicht abgewandelt übernommen werden, entstehen redundante Datensätze, die Marktanalysen verfälschen und unnötige Ressourcen binden. Ein robuster Deduplizierungsprozess, der inhaltlich gleiche, aber textlich abweichende Anzeigen ("Near-Duplicates") erkennt, ist daher die

---

<sup>1</sup> vgl. González-Flores u.a. (2025), S. 1ff.



absolute Grundvoraussetzung, bevor das eigentliche Lead-Scoring-Modell greifen und die relevantesten Anlässe zur Kundenansprache priorisieren kann.<sup>2</sup>

Um diese unstrukturierten Freitexte maschinell auswertbar zu machen, bilden fortschrittliche NLP-Methoden die technische Basis. Die Einführung der Transformer-Architektur hat die parallele Verarbeitung komplexer Textsequenzen durch sogenannte Aufmerksamkeitsmechanismen grundlegend revolutioniert.<sup>3</sup> In der heutigen Rekrutierungspraxis scheitern statische Parser und regelbasierte Filter häufig an der semantischen Komplexität der menschlichen Sprache. Moderne Large Language Models (LLMs) sind hingegen in der Lage, nuancierte Anforderungen, wie implizite Remote-Optionen, detaillierte Vergütungsstrukturen oder spezifische Erfahrungslevel deutlich präziser zu extrahieren.<sup>4</sup>

Darüber hinaus leiden viele online verfügbare Stellenanzeigen unter geringer Qualität oder fehlenden Kontextinformationen, was die algorithmische Bewertung der Passgenauigkeit erschwert. Durch LLM-gestützte Datenaugmentierung lassen sich derartige Vakanzen mit relevanten Branchenanforderungen anreichern, wodurch die Leistung von Matching-Algorithmen signifikant gesteigert wird.<sup>5</sup> Auch der Einsatz von Deep-Learning-Verfahren in Kombination mit synthetisch generierten Trainingsdaten hat sich als äußerst effektiv erwiesen, um die automatisierte Multi-Class-Klassifikation von heterogenen Berufskategorien zu optimieren.<sup>6</sup>

Bei der Wahl der zugrundeliegenden Sprachmodelle zeigt die aktuelle Forschung, dass einsprachige (monolinguale) Architekturen bei spezifischen Fachaufgaben oftmals ressourceneffizientere und präzisere Ergebnisse erzielen als generische, mehrsprachige Modelle.<sup>7</sup>

---

<sup>2</sup> vgl. Thivaios u.a. (2026), S. 1ff.

<sup>3</sup> vgl. Vaswani u.a. (2017)

<sup>4</sup> vgl. Thakrar; Young (2025), S. 4ff.

<sup>5</sup> vgl. Chen u.a. (2026), S. 1ff.

<sup>6</sup> vgl. Skondras u.a. (2023), S. 1–2

<sup>7</sup> vgl. Scheible u.a. (2024), S. 1ff.

Zudem profitiert die Modellgüte erheblich von einem domänenspezifischen Pre-Training. Modelle, die ausschließlich mit Fachtexten trainiert wurden, übertreffen generische Sprachmodelle in branchenspezifischen Analysen oftmals deutlich, da sie das einzigartige Vokabular der jeweiligen Domäne exakt abbilden können. Für die Automatisierung in der Personalberatung impliziert dies, dass kompakte, auf den deutschen HR-Kontext feinabgestimmte NLP-Modelle das höchste Potenzial für eine präzise Relevanzklassifikation bieten.<sup>8</sup>

Gleichzeitig muss das Risiko von algorithmischer Voreingenommenheit minimiert werden. Werden LLMs als automatisierte Evaluatoren ("LLM-as-a-Judge") eingesetzt, können sie signifikante eigene Verzerrungen aufweisen. Hierzu zählt beispielsweise die unbewusste Bevorzugung bestimmter Kriterien aufgrund ihrer Reihenfolge oder ihrer spezifischen Benennung auch Score ID Bias genannt.<sup>9</sup> Die Entwicklung des geplanten Scoring-Artefakts verlangt daher nicht nur technische Präzision, sondern auch ein robustes Governance-Framework, um faire und unvoreingenommene Bewertungen der Vertriebs-Leads sicherzustellen.

---

<sup>8</sup> vgl. Scherrmann (2023)

<sup>9</sup> vgl. Li u.a. (2026), S. 2ff.

### 3. Forschungsfragen und Ziel der Arbeit

Im Rahmen der geplanten Bachelorarbeit soll die übergeordnete Fragestellung „Wie kann der mehrstufige Prozess der vertriebslichen Stellenbeobachtung durch den Einsatz von NLP hinsichtlich Performanz und Effizienz optimiert werden, um das bisherige regelbasierte System abzulösen?“ Main Research Question (MRQ) beantwortet werden. Die Ausarbeitung unterteilt sich dabei methodisch in drei systematische Bestandteile mit jeweils individuellen Research Question (RQ), um die Thematik strukturiert zu erfassen:

1. Modellauswahl und Datenaufbereitung: Dieser Bestandteil fokussiert sich auf die Evaluierung der technologischen Grundlagen zur Bewältigung der unstrukturierten Datenmengen. Hierbei soll die Frage „Welche NLP-Architekturen und Sprachmodelle eignen sich technologisch am besten für die aufeinanderfolgenden Prozessschritte der Relevanzklassifikation und semantischen Dublettenerkennung?“ (RQ1) untersucht werden.
2. Entwicklung einer Bewertungslogik für das Lead-Scoring: Zur Erfassung und Priorisierung relevanter Vakanzen soll im Rahmen der Bachelorarbeit ein fundierter Anforderungskatalog entwickelt werden. Die Entwicklung orientiert sich an der Frage: „Anhand welcher Kriterien und Metriken lässt sich ein effizientes B2B-Lead-Scoring-Modell entwickeln, das Vakanzen präzise priorisiert und gleichzeitig Risiken wie algorithmische Verzerrungen (Algorithmic Bias) minimiert?“ (RQ2).
3. Evaluation und Systemintegration: Im dritten Teil der Thesis soll die Forschungsfrage „Inwiefern lässt sich das bestehende Workflow-System durch die implementierte NLP-Pipeline hinsichtlich definierter technischer und wirtschaftlicher Kennzahlen messbar optimieren?“ (RQ3) beantwortet werden. Mit dieser Fragestellung wird der direkte Leistungsvergleich zum bisherigen statischen Power-Automate-Skript gezogen, um dem Unternehmen eine fundierte Empfehlung auszusprechen.

Die Kombination aus den drei Bestandteilen der Bachelorarbeit soll eine Antwort auf die MRQ liefern, indem die Thematik aus theoretischer, integrativer und evaluativer Sicht beleuchtet wird.

Das primäre Ziel dieser Thesis ist die konkrete Planung, Entwicklung und Umsetzung eines funktionierenden System-Prototyps. Dabei ist es explizit nicht der Anspruch, eine allgemeingültige, branchentypische Automatisierungslösung für das gesamte Headhunting zu entwickeln. Vielmehr soll die konkrete Bestrebung der untersuchten Agentur aufgezeigt werden, die tägliche, unstrukturierte „Datenflut“ aus den Stellenbörsen durch intelligente NLP-Verfahren in für sich operable Kanäle zu gießen.

## 4. Methodik der Arbeit

Zum strukturierten Vorgehen der Untersuchung und zur fundierten Beantwortung der aufgestellten Forschungsfragen werden verschiedene wissenschaftliche Methoden eingesetzt. In der folgenden Abbildung 1 wird das methodische Vorgehen der Arbeit, aufgeteilt nach Kapiteln, Inhalten und der jeweiligen Forschungsstrategie, grafisch illustriert.

| Kapitel                         | Inhalt                                                                              | Forschungsmethodik                                        | Strategie                |
|---------------------------------|-------------------------------------------------------------------------------------|-----------------------------------------------------------|--------------------------|
| 1:<br>Einleitung                | Motivation, Problemstellung, Zielsetzung, Praxisrelevanz                            | Systematische Literaturrecherche (nach vom Brocke et al.) | Deskriptiv               |
| 2:<br>Theoretische Grundlage    | B2B-Lead-Scoring, NLP, Workflow-Automatisierung, Algorithmic Bias                   |                                                           |                          |
| 3:<br>Methodik                  | Forschungsdesign, DSRM, Definition kennzahlgestützte Analyse                        |                                                           |                          |
| 4:<br>Entwicklung & Integration | Konzeption des IT-Artefakts, semantische Dublettenerkennung, Lead-Scoring           | Design Science Research (DSRM nach Peffers et al.)        | Konstruktiv / Explorativ |
| 5:<br>Evaluation & Diskussion   | Quantitatives Experiment (NLP-Pipeline vs. altes Skript), Auswertung der Kennzahlen | Experimentelles Forschungsdesign, Quantitative Auswertung | Deskriptiv & Normativ    |
| 6:<br>Fazit und Ausblick        | Zusammenfassung und Beantwortung der Forschungsfragen                               | Synthese                                                  | Normativ                 |

Abbildung 1: Methodisches Vorgehen

Die methodische Grundlage für die Konzeption und Entwicklung des IT-Artefakts (die intelligente Daten-Pipeline) bildet die *Design Science Research Methodology* (DSRM) nach Peffers et al.<sup>10</sup> Dieser gestaltungsorientierte Forschungsansatz eignet sich besonders, da im Rahmen der geplanten Bachelorarbeit nicht nur theoretisches Wissen generiert, sondern ein innovatives und nützliches System zur Lösung eines praxisrelevanten Problems in der vertrieblichen Stellenbeobachtung geschaffen wird. Als Ausgangspunkt dient eine detaillierte Ist-Analyse des bisherigen, statischen Tools zur Stellenbeobachtung, um funktionale Limitationen (wie starre Keyword-Filter) aufzudecken. Die anschließende Entwicklungsphase zielt im Sinne der Ressourceneffizienz auf

<sup>10</sup> Vgl. ebd., S. 52–56

eine Systemintegration in Low-Code- bzw. Business-Intelligence-Umgebungen ab. Hierfür werden NLP-Technologien implementiert und mit historischen, unstrukturierten Stellenanzeigen der untersuchten Personalberatung trainiert.

Die Datenerhebung und technische Evaluation erfolgen im Rahmen eines experimentellen Forschungsdesigns. Zur Beantwortung der primären Forschungsfrage nach "Performanz und Effizienz" wird das neu orchestrierte System direkt dem bisherigen Power-Automate-Skript gegenübergestellt. Die Validierung der Modellgüte erfolgt anhand etablierter quantitativer Evaluationsmetriken: Die Qualität der Relevanzklassifikation wird mittels *Precision*, *Recall* und dem *F1-Score* gemessen (angestrebte Steigerung: +20 %). Die semantische Dublettenerkennung ("Near-Duplicates") wird über die *Accuracy* (Zielwert > 90 %) bewertet. Für die Beurteilung der Scoring-Logik wird eine *Spearman-Rangkorrelation* im Abgleich mit manuellen Expertenbewertungen berechnet (Zielwert > 0,8). Die Systemeffizienz wird über den wirtschaftlichen Ressourcenverbrauch in Form der Rechenzeit (*Runtime* < 5 Sekunden pro Job-Posting) evaluiert. Die theoretische Fundierung sowie die Ermittlung des aktuellen Forschungsstands erfolgen durch eine systematische Literaturrecherche, die sich an der Methodik von vom Brocke et al. orientiert.<sup>11</sup> Dieser Prozess wird begleitend zur Bearbeitung der Thesis fortgeführt. Zur Identifikation relevanter Fachliteratur wurden die thematischen Kernbereiche der Arbeit feingranular identifiziert und boolesche Operatoren eingesetzt, um Suchalgorithmen aus spezifischen Schlagworten zu erstellen. Dadurch wird sowohl eine hohe Präzision der Treffer als auch eine Vielzahl an relevanter Literatur ermöglicht. In den folgenden Tabellen sind die entsprechenden Suchalgorithmen in ihre jeweiligen Kerndomänen gruppiert dargestellt:

---

<sup>11</sup> Vgl. vom Brocke et al. (2015), S. 205–220

Tabelle 1: Übersicht Suchalgorithmus

| Thematik                                    | Suchstrings und Suchalgorithmen                                                                                                                                   |
|---------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| B2B Lead-Scoring & Priorisierung            | ("Lead Scoring" OR "Lead Prioritization" OR "B2B Sales") AND ("Machine Learning" OR "Predictive")                                                                 |
| NLP & Feature Extraction im Recruiting      | ("Natural Language Processing" OR "LLM") AND ("Recruitment" OR "Job Posting*" OR "Feature Extraction")                                                            |
| Semantische Dublettenerkennung              | ("job posting" OR "online recruitment") AND ("duplicate detection" OR "record linkage") AND "text similarity" ("job posting" AND "duplicate detection" AND "NLP") |
| Deutsche & Domänenspezifische Sprachmodelle | ("GermanBERT" OR "GBERT" OR "FinBERT" OR ("Language Model")) AND ("German" OR "Domain-Specific")                                                                  |
| Ethische Implikationen & Bias im Scoring    | ("Algorithmic Bias" OR "Scoring Bias" OR "Explainable AI") AND ("Recruitment" OR "Human Resources" OR "HR")                                                       |

Die definierten Suchalgorithmen werden auf ausgewählte wissenschaftliche Datenbanken angewendet, um fachspezifische Literatur zu identifizieren. Zu den primär genutzten Datenbanken gehören:

- IEEE Xplore <https://ieeexplore.ieee.org/xplore/home.jsp>
- Springer Link <https://link.springer.com/>
- Elsevier Science Direct <https://www.sciencedirect.com/>

- ACM Digital Library <https://dl.acm.org/>
- Google Scholar <https://scholar.google.de/>

|               |                                                                                                             |       |                                                                                             |                                                                                                                                                                                                                                                                                                                    |    |    |
|---------------|-------------------------------------------------------------------------------------------------------------|-------|---------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|----|
| IEEE Explorer | ("GermanBERT" OR "GBERT" OR "FinBERT" OR "Language Model") AND ("German" OR "Domain-Specific")              | 5.125 | IEEE Access                                                                                 | Y. Wang, J. Zhang, T. Shi, D. Deng, Y. Tian and T. Matsumoto, "Recent Advances in Interactive Machine Translation With Large Language Models," in IEEE Access, vol. 12, pp. 179353-179382, 2024, doi: 10.1109/                                                                                                     | Q1 | 23 |
| IEEE Explorer | ("GermanBERT" OR "GBERT" OR "FinBERT" OR "Language Model") AND ("German" OR "Domain-Specific")              | 5.125 | 3rd International Conference on Foundation and Large Language Models (FLLM)                 | E.-L. Ahlers and M. Schilling, "Classifying German Language Proficiency Levels Using Large Language Models," 2025 3rd International Conference on Foundation and Large Language Models (FLLM), Vienna, Austria, 2025, pp. 638-645, doi: 10.1109/FLLM67465.2025.11390912.                                           | -  | -  |
| IEEE Explorer | ("Lead Scoring" OR "Lead Prioritization" OR "B2B Sales") AND ("Machine Learning" OR "Predictive")           | 16    | International Conference on Electronics, Computing and Communication Technologies (CONECCT) | M. Tomer, R. Siddalingappa and J. Jayapriya, "AI-Driven Lead Scoring: Enhancing Real Estate Decisions with Predictive Analytics," 2025 IEEE International Conference on Electronics, Computing and Communication Technologies (CONECCT), Bengaluru, India, 2025, pp. 1-6, doi: 10.1109/CONECCT65861.2025.11306700. | -  | -  |
| IEEE Explorer | ("Lead Scoring" OR "Lead Prioritization" OR "B2B Sales") AND ("Machine Learning" OR "Predictive")           | 16    | 2019 IEEE 5th International Conference on Big Data Intelligence and Computing (DATACOM)     | V. Silber-Varod et al., "Computational modelling of speech data integration to assess interactions in B2B sales calls," 2019 IEEE 5th International Conference on Big Data Intelligence and Computing (DATACOM), Kaohsiung, Taiwan, 2019, pp. 152-157, doi: 10.1109/DataCom.2019.00031.                            | -  | -  |
| IEEE Explorer | ("Algorithmic Bias" OR "Scoring Bias" OR "Explainable AI") AND ("Recruitment" OR "Human Resources" OR "HR") | 247   | 2024 3rd International Conference on Embedded Systems and Artificial Intelligence (ESAI)    | A. Jamal, K. Aissaoui and S. Kassal, "Enhancing Recruitment Transparency and Efficiency with Explainable AI (XAI)," 2024 3rd International Conference on Embedded Systems and Artificial Intelligence (ESAI), Fez, Morocco, 2024, pp. 1-6, doi: 10.1109/ESAI62891.2024.10913744.                                   | -  | -  |
| IEEE Explorer | ("Algorithmic Bias" OR "Scoring Bias" OR "Explainable AI") AND ("Recruitment" OR "Human Resources" OR "HR") | 247   | IEEE International Symposium on Technology and Society (ISTAS)                              | D. F. Mujtaba and N. R. Mahapatra, "Ethical Considerations in AI-Based Recruitment," 2019 IEEE International Symposium on Technology and Society (ISTAS), Medford, MA, USA, 2019, pp. 1-7, doi: 10.1109/ISTAS48451.2019.8937920.                                                                                   | -  | 91 |

Abbildung 2: Ausschnitt Literaturrecherche Teil 1



|               |                                                                                                             |       |                                                           |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |    |    |
|---------------|-------------------------------------------------------------------------------------------------------------|-------|-----------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|----|
| Springer Link | ("Lead Scoring" OR "Lead Prioritization" OR "B2B Sales") AND ("Machine Learning" OR "Predictive")           | 414   | Journal of Information                                    | Rodriguez, M., Peterson, R. Artificial intelligence in business-to-business (B2B) sales process: a conceptual framework. <i>J Market Anal</i> 12, 778–789 (2024). <a href="https://doi.org/10.1057/s41270-023-00287-7">https://doi.org/10.1057/s41270-023-00287-7</a>                                                                                                                                                                                                                                                                  | Q2 | 33 |
| Springer Link | ("Lead Scoring" OR "Lead Prioritization" OR "B2B Sales") AND ("Machine Learning" OR "Predictive")           | 414   | Asset Analytics (Springer)                                | Josephine, V.L.H., Sai, C., Joy, J., Kashyup, A.A. (2025). Contact to Customer Lead Generation Predictive Model Using Machine Learning Techniques. In: Kapur, P.K., Alhazmi, O., Singhal, S. (eds) <i>Data-centric Approaches to Industrial Decisions</i> . Asset Analytics. Springer, Singapore. <a href="https://doi.org/10.1007/978-981-96-7556-2_9">https://doi.org/10.1007/978-981-96-7556-2_9</a>                                                                                                                                | -  | 1  |
| Springer Link | ("Algorithmic Bias" OR "Scoring Bias" OR "Explainable AI") AND ("Recruitment" OR "Human Resources" OR "HR") | 3.142 | Information Systems Engineering and Management (Springer) | Jayadharshini, P., Karunakaran, P., Santhiya, S., Renugadevi, A.S., Dhanush, G., Pavithra, E. (2025). Mitigating Bias in AI Recruitment Through Explainable AI for Fair and Inclusive Hiring Practices. In: Krishnasamy, L., Dhanaraj, R.K., Pamucar, D., Ouaisa, M. (eds) <i>Distributed Deep Learning and Explainable AI (XAI) in Industry 4.0</i> . Information Systems Engineering and Management, vol 55. Springer, Cham. <a href="https://doi.org/10.1007/978-3-031-94637-0_14">https://doi.org/10.1007/978-3-031-94637-0_14</a> | -  | 1  |
| Springer Link | ("Algorithmic Bias" OR "Scoring Bias" OR "Explainable AI") AND ("Recruitment" OR "Human Resources" OR "HR") | 3.142 | Discover Sustainability                                   | Koteczki, R., Csikor, D. & Balassa, B.E. The role of generative AI in improving the sustainability and efficiency of HR recruitment process. <i>Discov Sustain</i> 6, 601 (2025). <a href="https://doi.org/10.1007/s43621-025-01484-3">https://doi.org/10.1007/s43621-025-01484-3</a>                                                                                                                                                                                                                                                  | Q1 | 12 |
| Springer Link | ("GermanBERT" OR "GBERT" OR "FinBERT") AND ("German" OR "Domain-Specific")                                  | 260   | Society, Environment and Statistics                       | Fiedler, L., Hofmann, B., Loogman, K., Scherl, T. (2025). Domain Adaptation of a BERT Model for Analyzing Job Advertisements at the German Federal Employment Agency. In: Dumpert, F. (eds) <i>Foundations and Advances of Machine Learning in Official Statistics</i> . Society, Environment and Statistics. Springer, Cham. <a href="https://doi.org/10.1007/978-3-032-10004-7_9">https://doi.org/10.1007/978-3-032-10004-7_9</a>                                                                                                    | -  | 2  |

Abbildung 3: Ausschnitt Literaturrecherche Teil 2

|                         |                                                                                                       |        |                                    |                                                                                                                                                                                                                                                                                                       |       |    |
|-------------------------|-------------------------------------------------------------------------------------------------------|--------|------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------|----|
| Elsevier Science direct | ("GermanBERT" OR "GBERT" OR "FinBERT" OR "Language Model") AND ("German" OR "Domain-Specific")        | 18.863 | Journal of Systems and Software    | D. Delgado, L. Burgueño, and R. Clarisó, "A framework for assessing the capabilities of code generation of constraint domain-specific languages with large language models," <i>Journal of Systems and Software</i> , vol. 222 (provisorisch), Art. Nr. 112871, 2026, doi: 10.1016/j.jss.2026.112871. | Q1    | -  |
| Elsevier Science direct | ("GermanBERT" OR "GBERT" OR "FinBERT") AND ("German" OR "Domain-Specific")                            | 18.863 | Procedia Computer Science          | D. Uysal, D. Toka, E. Bozkurt, O. Kumaş, and H. H. Yılmaz, "Enhancing Financial NLP with Supercomputing: Spell Correction and Domain-Specific BERT Pretraining," <i>Procedia Computer Science</i> , vol. 263 (provisorisch), pp. 1-10, 2025, doi: 10.1016/j.procs.2025.08.244.                        | H-169 | -  |
| Elsevier Science direct | ("Lead Scoring" OR "Lead Prioritization" OR "B2B Sales") AND ("Machine Learning" OR "Predictive")     | 519    | Machine Learning with Applications | D. Saha, T. M. Young, and J. Thacker, "Predicting firm performance and size using machine learning with a Bayesian perspective," <i>Management Review Quarterly</i> , vol. 75, no. 1, pp. 125-148, Mar. 2023, doi: 10.1007/s11301-023-00326-w.                                                        | Q1    | 14 |
| Elsevier Science direct | ("Natural Language Processing" OR "LLM") AND ("Recruitment" OR "Job Posting" OR "Feature Extraction") | 34.890 | Array open access                  | T. H. Zadid et al., "A review of fairness challenges in natural language processing," <i>Journal of Systems and Software</i> , vol. 222 (provisorisch), Art. Nr. 112871, 2026, doi: 10.1016/j.jss.2026.112871.                                                                                        | Q1    | -  |
| Elsevier Science direct | ("Natural Language Processing" OR "LLM") AND ("Recruitment" OR "Job Posting" OR "Feature Extraction") | 34.890 | Expert Systems with Applications   | X. Zhang et al., "Natural language processing and text mining in transportation: Current status, challenges, and future roadmap," <i>Communications in Transportation Research</i> , vol. 5 (provisorisch), Art. Nr. 100154, 2025, doi: 10.1016/j.commtr.2025.100154.                                 | Q1    | 5  |

Abbildung 4: Ausschnitt Literaturrecherche Teil 3

|                     |                                                                                                             |        |                                                          |                                                                                                                                                                                                                                                                                                                                                                                                     |    |    |
|---------------------|-------------------------------------------------------------------------------------------------------------|--------|----------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|----|
| ACM Digital Library | ("Natural Language Processing" OR "LLM") AND ("Recruitment" OR "Job Posting" OR "Feature Extraction")       | 12.606 | Conference ACM                                           | Rui Zhu and Qiaojuan Hui. 2025. Research on Automatic Scoring System of College English Writing Based on Natural Language Processing. In Proceedings of the 2024 2nd International Conference on Information Education and Artificial Intelligence (ICIEAI '24). Association for Computing Machinery, <a href="https://doi.org/10.1145/3724504.3724597">https://doi.org/10.1145/3724504.3724597</a> | -  | 2  |
| ACM Digital Library | ("Algorithmic Bias" OR "Scoring Bias" OR "Explainable AI") AND ("Recruitment" OR "Human Resources" OR "HR") | 1.452  | ACM DIS '24                                              | M. Bhat and D. Long, "Designing Interactive Explainable AI Tools for Algorithmic Literacy and Transparency," in Proceedings of the 2024 ACM Designing Interactive Systems Conference (DIS '24), New York, NY, USA: ACM, 2024, pp. 939–957, doi: 10.1145/3643834.3660722.                                                                                                                            | -  | 27 |
| ACM Digital Library | ("Algorithmic Bias" OR "Scoring Bias" OR "Explainable AI") AND ("Recruitment" OR "Human Resources" OR "HR") | 1.452  | Journal of Artificial Intelligence Research              | Uwe Peters and Mary Carman. 2024. Cultural Bias in Explainable AI Research: A Systematic Analysis. J. Artif. Int. Res. 79 (Apr 2024). <a href="https://doi.org/10.1613/jair.1.14888">https://doi.org/10.1613/jair.1.14888</a>                                                                                                                                                                       | Q1 | 8  |
| ACM Digital Library | ("GermanBERT" OR "GBERT" OR "FinBERT" OR "Language Model") AND ("German" OR "Domain-Specific")              | 8.133  | ACM Transactions on Software Engineering and Methodology | Gu, X., Chen, M., Lin, Y., Hu, Y., Zhang, H., Wan, C., Wei, Z., Xu, Y., & Wang, J. (2025). On the Effectiveness of Large Language Models in Domain-Specific Code Generation. ACM Transactions on Software Engineering and Methodology, 34(3), Article 78. <a href="https://doi.org/10.1145/3697012">https://doi.org/10.1145/3697012</a>                                                             | Q1 | 34 |
| ACM Digital Library | ("GermanBERT" OR "GBERT" OR "FinBERT" OR "Language Model") AND ("German" OR "Domain-Specific")              | 8.133  | ACM Transactions on Knowledge Discovery from Data        | Susnjak, T., Hwang, P., Reyes, N., Barczak, A. L. C., McIntosh, T., & Ranathunga, S. (2025). Automating Research Synthesis with Domain-Specific Large Language Model Fine-Tuning. ACM Transactions on Knowledge Discovery from Data, 19(3), Article 68. <a href="https://doi.org/10.1145/3715964">https://doi.org/10.1145/3715964</a>                                                               | Q1 | 43 |

Abbildung 5: Ausschnitt Literaturrecherche Teil 4

|                |                                                                                                       |        |                                                                                                               |                                                                                                                                                                                                                                                                                                                                                |    |    |
|----------------|-------------------------------------------------------------------------------------------------------|--------|---------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|----|
| Google Scholar | ("Lead Scoring" OR "Lead Prioritization" OR "B2B Sales") AND ("Machine Learning" OR "Predictive")     | 6.940  | Frontiers in Artificial Intelligence                                                                          | González-Flores L, Rubiano-Moreno J and Sosa-Gómez G (2025) The relevance of lead prioritization: a B2B lead scoring model based on machine learning. Front. Artif. Intell. 8: 1554325. doi: 10.3389/frai.2025.1554325                                                                                                                         | Q1 | 14 |
| Google Scholar | ("Lead Scoring" OR "Lead Prioritization" OR "B2B Sales") AND ("Machine Learning" OR "Predictive")     | 6.940  | HICSS                                                                                                         | Nygård, Robert, and József Mezei. "Automating lead scoring with machine learning: An experimental study." (2020).                                                                                                                                                                                                                              | -  | 43 |
| Google Scholar | ("Natural Language Processing" OR "LLM") AND ("Recruitment" OR "Job Posting" OR "Feature Extraction") | 62.600 | First International Conference on Innovations in Communications, Electrical and Computer Engineering (ICICEC) | V. V. A. A and S. A. M U, "Optimization of HR Recruitment Process using Large Language Model (LLM)," 2024 First International Conference on Innovations in Communications, Electrical and Computer Engineering (ICICEC), Davangere, India, 2024, pp. 1-5, doi: 10.1109/ICICEC62498.2024.10808420.                                              | -  | 6  |
| Google Scholar | ("Natural Language Processing" OR "LLM") AND ("Recruitment" OR "Job Posting" OR "Feature Extraction") | 62.601 | ICBDS                                                                                                         | N. Jayakumar, N. Patil, R. S. Pokal, R. P. Dev and S. Nair, "Optimizing Job Search: A Multi-Model Approach with DRNN-BES, Collaborative Filtering, and LLM-NER Resume Analysis," 2024 IEEE International Conference on Blockchain and Distributed Systems Security (ICBDS), Pune, India, 2024, pp. 1-6, doi: 10.1109/ICBDS61829.2024.10837376. | -  | 2  |
| Google Scholar | "job posting" AND "duplicate detection" AND "NLP"                                                     | 39     | Information (mdpi)                                                                                            | Thivaos, G.; Zervas, P.; Giotopoulos, K.; Tzimas, G. On the Task of Job Posting Deduplication Using Embedding-Based Filtering and LLM Validation. Information 2026, 17, 233. <a href="https://doi.org/10.3390/info17030233">https://doi.org/10.3390/info17030233</a>                                                                           | Q2 | -  |

Abbildung 6: Ausschnitt Literaturrecherche Teil 5

## 5. Vorläufige Gliederung der Bachelor-Thesis

Die folgende Gliederung beschreibt den vorläufigen Aufbau der Bachelor-Arbeit und wird voraussichtlich einen Umfang von ungefähr 45 bis 55 Seiten einnehmen.

*Tabelle 2: Vorläufige Gliederung der Bachelorthesis Teil 1*

| Kapitel                                                                                                                                                                                                                                                   | Anzahl der Seiten |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------|
| <b>Abstract</b>                                                                                                                                                                                                                                           | 1                 |
| <b>1. Einleitung</b><br>1.1 Einführung in die Thematik<br>1.2 Problemstellung und Motivation<br>1.3 Forschungsfrage und Zielsetzung<br>1.4 Praxisrelevanz der Arbeit<br>1.5 Aufbau der Struktur                                                           | 3-4               |
| <b>2. Theoretische Grundlagen</b><br>2.1 B2B-Vertrieb, Marktanalyse und Lead-Scoring<br>2.2 Natural Language Processing<br>2.3 Domänenspezifische und deutsche Sprachmodelle<br>2.4 Ethische Implikationen und Algorithmic Bias                           | 13-15             |
| <b>3 Methodik</b><br>3.1 Aufbau des Forschungsdesigns<br>3.2 Systematische Literaturrecherche<br>3.3 Design Science Research Methodik<br>3.4 Experimenteller Aufbau und Systemintegration<br>3.5 Quantitative Evaluationsmetriken (Precision, Recall, F1) | 6-8               |

Tabelle 3: Vorläufige Gliederung der Bachelorthesis Teil 2

| Kapitel                                                                                                                                                                                                                                                                                                                | Anzahl der Seiten |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------|
| <b>4 Entwicklung und Systemintegration der Klassifikations- und Scoring-Pipeline</b><br>4.1 Ist-Analyse des bestehenden Power-Automate-Systems<br>4.2 Entwicklung der orchestrierten Daten-Pipeline<br>4.3 Konzeption und Implementierung der Scoring-Logik<br>4.4 Kennzahlengestützte Evaluation des Workflow-Systems | 15-18             |
| <b>5 Diskussion</b><br>5.1 Interpretation der Ergebnisse der kennzahlengestützten Analyse<br>5.2 Wirtschaftliche und technische Skalierbarkeit für das Unternehmen<br>5.3 Grenzen der Untersuchung (Limitationen)<br>5.4 Zukünftiger Forschungsbedarf                                                                  | 5-8               |
| <b>6 Fazit und Ausblick</b>                                                                                                                                                                                                                                                                                            | 1-2               |
| <b>Literaturverzeichnis</b>                                                                                                                                                                                                                                                                                            | /                 |
| <b>KI-Disclaimer</b>                                                                                                                                                                                                                                                                                                   | /                 |

## 6. Ergebnis der Literaturrecherche

- Ahlers, E.-L.; Schilling, M. (2025):** Classifying German Language Proficiency Levels Using Large Language Models. Vienna, Austria, S. 638–645
- Amity University; Institute of Electrical and Electronics Engineers (Hrsg.) (2024):** Proceedings of International Conference on Contemporary Computing and Informatics (IC3I): 18th-20th September 2024. Piscataway, NJ: IEEE
- Bhat, M.; Long, D. (2024):** Designing Interactive Explainable AI Tools for Algorithmic Literacy and Transparency. New York, NY, USA: ACM, S. 939–957
- Chen, Minping; Xu, Bing; Chen, Zulong; Xu, Chuanfei; Zhou, Ying; Tao, Zui; Wen, Zeyi (2026):** Enhancing Online Recruitment with Category-Aware MoE and LLM-based Data Augmentation. arXiv, URL: <http://arxiv.org/abs/2604.21264> [Zugriff: 3.5.2026], arXiv:2604.21264 [cs]
- Delgado, D.; Burgueño, L.; Clarisó, R. (2026):** A framework for assessing the capabilities of code generation of constraint domain-specific languages with large language models. In: *Journal of Systems and Software*, Band 222, 2026
- Fiedler, L.; Hofmann, B.; Loogman, K.; Scherl, T. (2025):** Domain Adaptation of a BERT Model for Analyzing Job Advertisements at the German Federal Employment Agency. *Society, Environment and Statistics*. Cham: Springer
- González-Flores, L.; Rubiano-Moreno, J.; Sosa-Gómez, G. (2025):** The relevance of lead prioritization: a B2B lead scoring model based on machine learning. In: *Frontiers in Artificial Intelligence*, Band 8, 2025
- Gu, X.; Chen, M.; Lin, Y.; Hu, Y.; Zhang, H.; Wan, C.; Wei, Z.; Xu, Y.; Wang, J. (2025):** On the Effectiveness of Large Language Models in Domain-Specific Code Generation. In: *ACM Transactions on Software Engineering and Methodology*, Band 34, Ausgabe 3, 2025
- Jamal, A.; Aissaoui, K.; Kassal, S. (2024):** Enhancing Recruitment Transparency and Efficiency with Explainable AI (XAI). Fez, Morocco, S. 1–6
- Jayadharshini, P.; Karunakaran, P.; Santhiya, S.; Renugadevi, A.S.; Dhanush, G.; Pavithra, E. (2025):** Mitigating Bias in AI Recruitment Through Explainable AI for Fair and Inclusive Hiring Practices. *Information Systems Engineering and Management*. Cham: Springer

- Jayakumar, N.; Patil, N.; Pokal, R. S.; Dev, R. P.; Nair, S. (2024):** Optimizing Job Search: A Multi-Model Approach with DRNN-BES, Collaborative Filtering, and LLM-NER Resume Analysis. Pune, India, S. 1–6
- Josephine, V.L.H.; Sai, C.; Joy, J.; Kashyup, A.A. (2025):** Contact to Customer Lead Generation Predictive Model Using Machine Learning Techniques. *Asset Analytics*. Singapore: Springer
- Köchling, Alina; Wehner, Marius Claus (2020):** Discriminated by an algorithm: a systematic review of discrimination and fairness by algorithmic decision-making in the context of HR recruitment and HR development. In: *Business Research*, Band 13, Ausgabe 3, 11.2020, S. 795–848
- Koteczki, R.; Csikor, D.; Balassa, B.E. (2025):** The role of generative AI in improving the sustainability and efficiency of HR recruitment process. In: *Discover Sustainability*, Band 6, 2025
- Li, Qingquan; Dou, Shaoyu; Shao, Kailai; Chen, Chao; Hu, Haixiang (2026):** Evaluating Scoring Bias in LLM-as-a-Judge. arXiv, URL: <http://arxiv.org/abs/2506.22316> [Zugriff: 10.5.2026], arXiv:2506.22316 [cs]
- Mujtaba, D. F.; Mahapatra, N. R. (2019):** Ethical Considerations in AI-Based Recruitment. Medford, MA, USA, S. 1–7
- Nygård, Robert; Mezei, József (2020):** Automating lead scoring with machine learning: An experimental study
- Patil, Kedar; Scholar II, Research (2025):** Algorithmic Decision-Making in HR: Navigating Fairness, Transparency, and Governance in the Age of AI. In: *INTERNATIONAL JOURNAL OF COMPUTER ENGINEERING & TECHNOLOGY*, Band 16, 9.1.2025, S. 359–367
- Peffer, Ken; Tuunanen, Tuure; Rothenberger, Marcus A.; Chatterjee, Samir (2007):** A Design Science Research Methodology for Information Systems Research. In: *Journal of Management Information Systems*, Band 24, Ausgabe 3, 12.2007, S. 45–77
- Peters, Uwe; Carman, Mary (2024):** Cultural Bias in Explainable AI Research: A Systematic Analysis. In: *Journal of Artificial Intelligence Research*, Band 79, 2024
- Rodriguez, M.; Peterson, R. (2024):** Artificial intelligence in business-to-business (B2B) sales process: a conceptual framework. In: *Journal of Marketing Analytics*, Band 12, 2024, S. 778–789
- Saha, D.; Young, T. M.; Thacker, J. (2023):** Predicting firm performance and size using machine learning with a Bayesian perspective. In: *Management Review Quarterly*, Band 75, Ausgabe 1, 2023, S. 125–148

- Scheible, Raphael; Frei, Johann; Thomczyk, Fabian; He, Henry; Tippmann, Patric; Knaus, Jochen; Jaravine, Victor; Kramer, Frank; Boeker, Martin (2024):** GottBERT: a pure German Language Model. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Miami, Florida, USA: Association for Computational Linguistics, S. 21237–21250, URL: <https://aclanthology.org/2024.emnlp-main.1183> [Zugriff: 10.5.2026]
- Scherrmann, Moritz (2023):** German FinBERT: A German Pre-trained Language Model. arXiv, URL: <http://arxiv.org/abs/2311.08793> [Zugriff: 10.5.2026], arXiv:2311.08793 [cs]
- Silber-Varod, V.; et al. (2019):** Computational modelling of speech data integration to assess interactions in B2B sales calls. Kaohsiung, Taiwan, S. 152–157
- Sioziou, Kyriaki; Zervas, Panagiotis; Giotopoulos, Kostas; Tzimas, Giannis (2024):** Comparative Analysis of Large Language Models in Structured Information Extraction from Job Postings. In: Iliadis, Lazaros; Maglogiannis, Ilias; Papaleonidas, Antonios; Pimenidis, Elias; Jayne, Chrisina (Hrsg.), *Engineering Applications of Neural Networks*. Cham: Springer Nature Switzerland, S. 82–92, URL: [https://link.springer.com/10.1007/978-3-031-62495-7\\_7](https://link.springer.com/10.1007/978-3-031-62495-7_7) [Zugriff: 3.5.2026]
- Skondras, Panagiotis; Zotos, Nikos; Lagios, Dimitris; Zervas, Panagiotis; Giotopoulos, Konstantinos C.; Tzimas, Giannis (2023):** Deep Learning Approaches for Big Data-Driven Metadata Extraction in Online Job Postings. In: *Information*, Band 14, Ausgabe 11, 25.10.2023, S. 585
- Susnjak, T.; Hwang, P.; Reyes, N.; Barczak, A. L. C.; McIntosh, T.; Ranathunga, S. (2025):** Automating Research Synthesis with Domain-Specific Large Language Model Fine-Tuning. In: *ACM Transactions on Knowledge Discovery from Data*, Band 19, Ausgabe 3, 2025
- Thakrar, Karishma; Young, Nick (2025):** Enhancing Talent Employment Insights Through Feature Extraction with LLM Finetuning. arXiv, URL: <http://arxiv.org/abs/2501.07663> [Zugriff: 7.5.2026], arXiv:2501.07663 [cs]
- Thivaïos, G.; Zervas, P.; Giotopoulos, K.; Tzimas, G. (2026):** On the Task of Job Posting Deduplication Using Embedding-Based Filtering and LLM Validation. In: *Information*, Band 17, Ausgabe 3, 2026
- Thivaïos, Giannis; Zervas, Panagiotis; Tzimas, Giannis (2025):** LLM-Driven Evaluation of Text Embedding Similarities for JobPosting Deduplication. Computer Science and Mathematics, URL: <https://www.preprints.org/manuscript/202506.1143/v1> [Zugriff: 7.5.2026]

- Tomer, M.; Siddalingappa, R.; Jayapriya, J. (2025):** AI-Driven Lead Scoring: Enhancing Real Estate Decisions with Predictive Analytics. Bengaluru, India, S. 1–6
- Uysal, D.; Toka, D.; Bozkurt, E.; Kumaş, O.; Yılmaz, H. H. (2025):** Enhancing Financial NLP with Supercomputing: Spell Correction and Domain-Specific BERT Pretraining. In: *Procedia Computer Science*, Band 263, 2025, S. 1–10
- V., V.; A., A.; S. A. M., U. (2024):** Optimization of HR Recruitment Process using Large Language Model (LLM). Davangere, India, S. 1–5
- Vaswani, Ashish; Shazeer, Noam; Parmar, Niki; Uszkoreit, Jakob; Jones, Llion; Gomez, Aidan N; Kaiser, Łukasz; Polosukhin, Illia (2017):** Attention is All you Need. 2017
- vom Brocke et al. (2015):** (PDF) Standing on the Shoulders of Giants: Challenges and Recommendations of Literature Search in Information Systems Research. In: *ResearchGate*, 2015, URL: [https://www.researchgate.net/publication/281065428\\_Standing\\_on\\_the\\_Shoulders\\_of\\_Giants\\_Challenges\\_and\\_Recommendations\\_of\\_Literature\\_Search\\_in\\_Information\\_Systems\\_Research](https://www.researchgate.net/publication/281065428_Standing_on_the_Shoulders_of_Giants_Challenges_and_Recommendations_of_Literature_Search_in_Information_Systems_Research) [Zugriff: 17.5.2026]
- Wang, Y.; Zhang, J.; Shi, T.; Deng, D.; Tian, Y.; Matsumoto, T. (2024):** Recent Advances in Interactive Machine Translation With Large Language Models. In: *IEEE Access*, Band 12, 2024, S. 179353–179382
- Zadid, T. H.; et al. (2026):** A review of fairness challenges in natural language processing. In: *Journal of Systems and Software*, Band 222, 2026
- Zhang, X.; et al. (2025):** Natural language processing and text mining in transportation: Current status, challenges, and future roadmap. In: *Communications in Transportation Research*, Band 5, 2025
- Zhu, Rui; Hui, Qiaojuan (2025):** Research on Automatic Scoring System of College English Writing Based on Natural Language Processing. Association for Computing Machinery



## 7. Vorläufige Zeitplanung

| Phase | Arbeitspaket                                       | Beginn     | Ende       | Graphische Darstellung |      |      |        |      |         |      |      |
|-------|----------------------------------------------------|------------|------------|------------------------|------|------|--------|------|---------|------|------|
|       |                                                    |            |            | Mai                    | Juni | Juli | August | Sep. | Oktober | Nov. | Dez. |
| 0     | Literaturrecherche und Theorie                     | 26.03.2026 | 14.09.2026 |                        |      |      |        |      |         |      |      |
| 1     | Anmeldung                                          | 28.06.2026 |            |                        |      |      |        |      |         |      |      |
| 2     | Ist Analyse des bestehenden Systems                | 28.06.2026 | 12.07.2026 |                        |      |      |        |      |         |      |      |
| 3     | Schreibphase                                       | 28.06.2026 | 14.09.2026 |                        |      |      |        |      |         |      |      |
| 4     | Entwicklung des IT-Artefakts                       | 12.07.2026 | 10.09.2026 |                        |      |      |        |      |         |      |      |
| 5     | Überarbeitung und Finalisierung                    | 14.09.2026 | 01.10.2026 |                        |      |      |        |      |         |      |      |
| 6     | Formale Endkontrolle und Abgabe der Bachelorarbeit | 01.10.2026 | 08.10.2026 |                        |      |      |        |      |         |      |      |
| 7     | Kolloquium                                         | 09.10.2026 | 15.12.2026 |                        |      |      |        |      |         |      |      |

Abbildung 7: Zeitplan Bachelorarbeit

## 8. Literaturverzeichnis

- Chen, Minping; Xu, Bing; Chen, Zulong; Xu, Chuanfei; Zhou, Ying; Tao, Zui; Wen, Zeyi (2026):** Enhancing Online Recruitment with Category-Aware MoE and LLM-based Data Augmentation. arXiv, URL: <http://arxiv.org/abs/2604.21264> [Zugriff: 3.5.2026], arXiv:2604.21264 [cs]
- González-Flores, Laura; Rubiano-Moreno, Jessica; Sosa-Gómez, Guillermo (2025):** The relevance of lead prioritization: a B2B lead scoring model based on machine learning. In: *Frontiers in Artificial Intelligence*, Band 8, 7.3.2025, URL: <https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2025.1554325/full> [Zugriff: 7.5.2026]
- Li, Qingquan; Dou, Shaoyu; Shao, Kailai; Chen, Chao; Hu, Haixiang (2026):** Evaluating Scoring Bias in LLM-as-a-Judge. arXiv, URL: <http://arxiv.org/abs/2506.22316> [Zugriff: 10.5.2026], arXiv:2506.22316 [cs]
- Peffer, Ken; Tuunanen, Tuure; Rothenberger, Marcus A.; Chatterjee, Samir (2007):** A Design Science Research Methodology for Information Systems Research. In: *Journal of Management Information Systems*, Band 24, Ausgabe 3, 12.2007, S. 45–77
- Scheible, Raphael; Frei, Johann; Thomczyk, Fabian; He, Henry; Tippmann, Patric; Knaus, Jochen; Jaravine, Victor; Kramer, Frank; Boeker, Martin (2024):** GottBERT: a pure German Language Model. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Miami, Florida, USA: Association for Computational Linguistics, S. 21237–21250, URL: <https://aclanthology.org/2024.emnlp-main.1183> [Zugriff: 10.5.2026]
- Scherrmann, Moritz (2023):** German FinBERT: A German Pre-trained Language Model. arXiv, URL: <http://arxiv.org/abs/2311.08793> [Zugriff: 10.5.2026], arXiv:2311.08793 [cs]
- Skondras, Panagiotis; Zotos, Nikos; Lagios, Dimitris; Zervas, Panagiotis; Giotopoulos, Konstantinos C.; Tzimas, Giannis (2023):** Deep Learning Approaches for Big Data-Driven Metadata Extraction in Online Job Postings. In: *Information*, Band 14, Ausgabe 11, 25.10.2023, S. 585
- Thakrar, Karishma; Young, Nick (2025):** Enhancing Talent Employment Insights Through Feature Extraction with LLM Finetuning. arXiv, URL: <http://arxiv.org/abs/2501.07663> [Zugriff: 7.5.2026], arXiv:2501.07663 [cs]
- Thivaos, G.; Zervas, P.; Giotopoulos, K.; Tzimas, G. (2026):** On the Task of Job Posting Deduplication Using Embedding-Based Filtering and LLM Validation. In: *Information*, Band 17, Ausgabe 3, 2026

**Vaswani, Ashish; Shazeer, Noam; Parmar, Niki; Uszkoreit, Jakob; Jones, Llion; Gomez, Aidan N; Kaiser, Łukasz; Polosukhin, Illia (2017):**  
Attention is All you Need. 2017

**vom Brocke et al. (2015):** (PDF) Standing on the Shoulders of Giants: Challenges and Recommendations of Literature Search in Information Systems Research. In: *ResearchGate*, 2015, URL: [https://www.researchgate.net/publication/281065428\\_Standing\\_on\\_the\\_Shoulders\\_of\\_Giants\\_Challenges\\_and\\_Recommendations\\_of\\_Literature\\_Search\\_in\\_Information\\_Systems\\_Research](https://www.researchgate.net/publication/281065428_Standing_on_the_Shoulders_of_Giants_Challenges_and_Recommendations_of_Literature_Search_in_Information_Systems_Research) [Zugriff: 17.5.2026]