

GML

Ökonometrie: Logit

All models are wrong but some are useful, turn data into assets

Prof. Dr. Frank Lehrbass

Copyright

**© FOM Hochschule für Oekonomie & Management
gemeinnützige Gesellschaft mbH (FOM), Leimkugelstraße 6, 45141 Essen**

Dieses Werk ist urheberrechtlich geschützt und nur für den persönlichen Gebrauch im Rahmen der Veranstaltungen der FOM bestimmt.

Die durch die Urheberschaft begründeten Rechte (u. a. Vervielfältigung, Verbreitung, Übersetzung, Nachdruck) bleiben dem Urheber vorbehalten.

Das Werk oder Teile daraus dürfen nicht ohne schriftliche Genehmigung des Urhebers / der FOM reproduziert oder unter Verwendung elektronischer Systeme verarbeitet, vervielfältigt oder verbreitet werden. Dies schließt auch den Upload in soziale Medien oder andere digitale Plattformen ein.

- Wir verwenden die genannten Bücher und geben die im Text Quellen wie folgt an:
- Verbeek, 2017, Seite xx
- Schröder, 2002, dito (Esp. dicho)
- Danielsson, 2011, dito
- Gehrke, 2022, dito

Logit Modell

Motivation

Unterstelle latente Variable a_i (Agitation = Erregung) wie folgt

$$a_i = c + b x_i + \varepsilon_i$$

Die ZV a_i bestimmt das beobachtbare binäre y_i : **$y_i = 1$ wenn $a_i > 0$, 0 sonst**

Die Wahrscheinlichkeit dafür ist:

$$P\{ y_i^* > 0 \mid x_i \} = P\{ -\varepsilon_i \leq c + b x_i \mid x_i \} = F(..),$$

F ist die Verteilungsfunktion für $-\varepsilon_i$.

Wir unterstellen, dass F die **logistische Verteilung** ist. ε_i gehorcht damit einer Standard-Logistischen-Verteilung (bei Probit Normal statt Logistisch).

Der Graph der logistischen Dichte ist ähnlich wie die Gauss-Glocke – nur etwas spitzer und höher.

Konkret:

Die latente Variable a könnte die Erregung sein, die ein männliches Säugetier im Autohaus verspürt. Überschreitet sie ein bestimmtes Niveau kommt es zum Kauf des Porsches/Mustang/usw..

Sie könnte aber auch die „Bonität“ sein. Überschreitet sie eine gewisse Schwelle, findet ein Upgrade statt.

Interpretation kontextabhängig!

Mathe immer dieselbe;-)

Logit Modell

Motivation konkret

Ausführen 1-41

Wir erzeugen eine Population von 1000 Autointeressenten

Der “Data Generating Process” (DGP) ist:

$c = -45$


$b = 0.9$

#latent variable with logistic error

$a = c + b \cdot x + e$

$y = (a > 0)$



Mit welchem Anteil an Käufen rechnen Sie?



Logit Modell

Was ist was?

Welcher Balken geht bis 375?



Hide and Seek again

Wir wollen nun unsere erste logistische Regression vornehmen

Ausführen von 43-56 ergibt

```
> fit1
logistf(formula = y ~ x, pl = FALSE, firth = F, method = "Standard ML")
Model fitted by Standard ML
Confidence intervals and p-values by Wald
```

	coef	se(coef)	lower 0.95	upper 0.95	Chisq	p
(Intercept)	-44.2140136	5.2058844	-54.4173596	-34.01067	Inf	0
x	0.8837828	0.1041229	0.6797057	1.08786	Inf	0

Likelihood ratio test=1184.934 on 1 df, p=0, n=1000

Was kommt Ihnen vertraut vor?

Mission accomplished?

Womit wurde geschätzt?

War das Zufall?

Hypothesentests erst danach!

```
> #COMPARE
> c(c, b)
[1] -45.0 0.9
> coef(fit1)
(Intercept) x
-44.2140136 0.8837828
> coef(fit2)
(Intercept) x
-44.2140136 0.8837828
```

```
> summary(fit2)
```

```
Call:
glm(formula = y ~ x, family = "binomial")
```

Deviance Residuals:

	Min	1Q	Median	3Q	Max
	-2.66072	-0.00447	-0.00002	0.00458	2.67882

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-44.2140	5.2059	-8.493	<2e-16 ***
x	0.8838	0.1041	8.488	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1323.13 on 999 degrees of freedom
 Residual deviance: 138.19 on 998 degrees of freedom
 AIC: 142.19

Number of Fisher Scoring iterations: 10

Verbeek, 2017, 193

“Under weak regularity conditions it can be shown that:

1. The ML estimator is consistent;
2. The ML estimator is **asymptotically** efficient
3. The ML estimator has an **asymptotic** normal distribution, according to

where V is the asymptotic covariance matrix. The matrix V ... can be estimated directly from the data. “

Warum habe ich nicht nur 100 Autokunden erzeugt?

Hypothesentests

Wir wollen nun unsere erste logistische Regression interpretieren

Dank des Satzes können wir die z values als normale ZV interpretieren

Werte absolut grosser als 2 markieren signifikante Einflüsse

Wo sehen Sie solche?

Zu welchem Test korrespondiert der "Wald Test" für $H_0: \beta = 0$?

Der LR Test testet $H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$.

Was kommt raus?

Rechnen Sie die Conf.Int. nach!

```
> summary(fit2)

Call:
glm(formula = y ~ x, family = "binomial")

Deviance Residuals:
    Min       1Q   Median       3Q      Max 
-2.66072  -0.00447  -0.00002   0.00458   2.67882 

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -44.2140     5.2059  -8.493  <2e-16 ***
x             0.8838     0.1041   8.488  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 1323.13  on 999  degrees of freedom
Residual deviance:  138.19  on 998  degrees of freedom
AIC: 142.19

Number of Fisher Scoring iterations: 10
```

```
> fit1
logistf(formula = y ~ x, pl = FALSE, firth = F, method = "Standard ML")
Model fitted by Standard ML
Confidence intervals and p-values by wald

              coef se(coef) lower 0.95 upper 0.95 Chisq p
(Intercept) -44.2140136 5.2058844 -54.4173596 -34.01067   Inf 0
x             0.8837828 0.1041229  0.6797057  1.08786   Inf 0

Likelihood ratio test=1184.934 on 1 df, p=0, n=1000
```

Einführung Modellgüte

Abgrenzung zur lin. Reg.

Wir haben nun ein Modell für dichotome/binäre Regressanden und können DGP aufspüren

Zur Beurteilung der Güte könne wir nicht das R^2 verwenden. Das Logit Modell prognostiziert Wahrscheinlichkeiten! $P\{y_i = 1 \mid x_i\}$. Dies führt zu zwei Besonderheiten:

In realen Anwendungen will man aber oft eine Null-Eins Prognose. Dafür nutzt man üblicherweise 0.5 als cut off threshold.

Zum zweiten ist die Definition eines Residuums schwierig. Da die Prognose eine Wahrscheinlichkeit ist, müsste man die wahre WS als Realisation kennen. Dies tut man aber nicht. Man kennt nur „1“ oder „0“. Deshalb kann man auch nicht einfach die Methoden der lin. Regression „recyclen“.

Verfahren zur Überprüfung der Heteroskedastizität usw. finden sich in Schröder (2002, 375) und Gehrke (2022) und werden hier nicht ausgeführt.

Wir überspringen somit die Diagnostik.

Wir messen die Modellgüte wie folgt:

Konfusionsmatrix

Taking the Confusion Out of Confusion Matrices

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

1. Accuracy (all **correct** / all) = $TP + TN / TP + TN + FP + FN$

2. Misclassification (all **incorrect** / all) = $FP + FN / TP + TN + FP + FN$

3. Precision (**true positives** / **predicted positives**) = $TP / TP + FP$

4. Sensitivity aka Recall (**true positives** / all **actual positives**) = $TP / TP + FN$

5. Specificity (**true negatives** / all **actual negatives**) = $TN / TN + FP$

Source: Understanding Confusion Matrix by Sarang Narkhede on Towards Data Science

Sie haben ein Ratingsystem mit zwei Stufen ausfallgefährdet/nicht agf. 20% der Stipo sind ausgefallen.

Mit welcher naiven Vorhersage erhalten Sie eine Genauigkeit (Accuracy) von 80% OHNE Modellierung?

Welcher Quadrant schmerzt am meisten? Was sollte Ihr Gütemaß sein?

Fallstudie Rating

Datenbasis

Datensatz von Verbeek (2017, Ch. 7)

„The files credit contain 921 observations for 2005 for US firms' credit ratings, including a set of firm characteristics. The data are taken from Compustat.“

Ausführen Step 1 Coding GML_03_02 rating.R

Ein RATING < 3 ist spekulativ

Was ist die beste Ratingstufe?

Wieviel Prozent haben ein IG?

Mit welcher naiven Vorhersage erhalten Sie eine Genauigkeit (Accuracy) von über 50% OHNE Modellierung?

```
> summary(dfrm_clean)
```

BOOKLEV	EBIT	INVGRADE	LOGSALES	MARKLEV
Min. :0.0000	Min. : -0.38417	Min. :0.0000	Min. : 1.100	Min. :0.0000
1st Qu.:0.1698	1st Qu.: 0.05120	1st Qu.:0.0000	1st Qu.: 6.970	1st Qu.:0.1091
Median :0.2640	Median : 0.09044	Median :0.0000	Median : 7.884	Median :0.2112
Mean :0.2932	Mean : 0.09389	Mean :0.4723	Mean : 7.996	Mean :0.2547
3rd Qu.:0.3877	3rd Qu.: 0.13599	3rd Qu.:1.0000	3rd Qu.: 8.950	3rd Qu.:0.3477
Max. :0.9992	Max. : 0.65151	Max. :1.0000	Max. :12.701	Max. :0.9649

RATING	RETA	WKA
Min. :1.000	Min. : -0.99589	Min. : -0.41208
1st Qu.:3.000	1st Qu.: 0.01108	1st Qu.: 0.02905
Median :3.000	Median : 0.18048	Median : 0.12284
Mean :3.499	Mean : 0.15699	Mean : 0.14041
3rd Qu.:4.000	3rd Qu.: 0.35084	3rd Qu.: 0.23462
Max. :7.000	Max. : 0.97992	Max. : 0.74802

Datenbasis

Datensatz von Verbeek (2017, Ch. 7)

„The files credit contain 921 observations for 2005 for US firms' credit ratings, including a set of firm characteristics. The data are taken from Compustat.“

Ausführen Step 1 Coding GML_03_02 rating.R

Ein RATING < 3 ist spekulativ

Welche Vorzeichen des Einflusses erwarten Sie?

Bezeichnung	Erläuterung
Datensatzgröße	921 Unternehmen
BOOKLEV	- Verschuldung / Buchwert der Assets - Leverage
EBIT	- Messgröße - aktuelle Profitabilität
LOGSALES	- Messgröße - Firmengröße
MARKLEV	- Verschuldung / Marktwert der Assets - Leverage
RETA	- Einbehaltene Gewinne - Messgröße - bisherige Rentabilität
WKA	- Messgröße - Liquidität auf Basis des WC


Fallstudie Rating

Datenbasis



Ausführen Step 1 Coding GML_03_02 rating.R

Gefallen die Histogramme auf der Hauptdiagonalen?

Welchen Zshg. vermuten Sie zwischen Booklev und Rating?



Welchen Zshg. vermuten Sie zwischen Logsales und Rating?



Fallstudie Rating

Modellierung

Ausführen Step 2 Coding GML_03_02 rating.R

Interpretieren Sie!

Was fehlt noch zum Test $H_0: \text{alle } \beta = 0$?

```
Call:
glm(formula = IG ~ booklev + ebit + logsales + re + wk, family = "binomial")

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-2.5840  -0.5411  -0.0491   0.5286   3.4210

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  -8.21432    0.86685  -9.476  < 2e-16 ***
booklev       -4.42727    0.77142  -5.739  9.52e-09 ***
ebit          4.35474    1.43992   3.024  0.00249 **
logsales      1.08159    0.09568  11.304  < 2e-16 ***
re            4.11611    0.48851   8.426  < 2e-16 ***
wk           -4.01249    0.74791  -5.365  8.10e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 1273.95  on 920  degrees of freedom
Residual deviance:  682.16  on 915  degrees of freedom
AIC: 694.16
```


Fallstudie Rating

Evaluation

Ausführen Step 2 Coding GML_03_02 rating.R

Interpretieren Sie!

Warum ist es sinnvoll, bei kostenloser SW auf 2
Wegen zu gehen?

```
> fit1
logistf(formula = IG ~ booklev + ebit + logsales + re + wk, pl = FALSE,
        firth = F, method = "Standard ML")
Model fitted by Standard ML
Confidence intervals and p-values by wald
```

	coef	se(coef)	lower 0.95	upper 0.95	Chisq	p
(Intercept)	-8.214322	0.86685440	-9.9133252	-6.515318	Inf	0.000000e+00
booklev	-4.427267	0.77141859	-5.9392193	-2.915314	32.93754	9.516771e-09
ebit	4.354736	1.43992244	1.5325399	7.176932	9.14630	2.492215e-03
logsales	1.081593	0.09568393	0.8940559	1.269130	Inf	0.000000e+00
re	4.116108	0.48850831	3.1586496	5.073567	Inf	0.000000e+00
wk	-4.012493	0.74791414	-5.4783773	-2.546608	28.78227	8.098930e-08

```
Likelihood ratio test=591.7964 on 5 df, p=0, n=921

> # Anzahl der Freiheitsgrade = Anzahl Koeffizienten minus Intercept
> df <- length(coef(fit2)) - 1
> # Chi2-Test
> pchisq(fit2$null.deviance - fit2$deviance, df, lower.tail = FALSE)
[1] 1.197621e-125
> ## R-Code 4.11 ----
> lrtest(fit2)
Likelihood ratio test

Model 1: IG ~ booklev + ebit + logsales + re + wk
Model 2: IG ~ 1
#Df LogLik Df Chisq Pr(>Chisq)
1 6 -341.08
2 1 -636.98 -5 591.8 < 2.2e-16 ***
```


Fallstudie Rating

Evaluation

Ausführen Step 3 Coding GML_03_02 rating.R

Definition: Relatives Risiko (Relative Risk):

Das relative Risiko ist definiert als das Verhältnis von Eintrittswahrscheinlichkeiten für die Zielgröße bei zwei unterschiedlichen Ausprägungen der Einflussgröße:

$$RR = \frac{p_1(x_1)}{p_1(x_2)}$$

Sei nun x_2 der gesamte Regressorvektor einer Beobachtung x_1 derjenige bei dem der k -te Regressor um eine Einheit erhöht worden ist.

Konkret seien hier die Logsales.

Dann ist die dadurch bedingte Veränderung im „Risiko“ wie folgt:

```
> exp(coef(fit2))
(Intercept)    booklev      ebit    logsales      re      wk
2.707481e-04  1.194710e-02  7.784627e+01  2.949374e+00  6.132014e+01  1.808825e-02
```

D.h. z. B. die Chance ein IG zu erhalten ist nach Erhöhung der Logsales (+1) **approximativ** etwa dreimal so gross wie vorher.


Fallstudie Rating

Theorie Nachtrag

Eine Konsequenz der Modellierung über die latente Variable mit logistischem Störterm lässt sich wie folgt explizit machen. Es sei $\eta = c + b \cdot x_i$. Dann wissen wir, dass:

$$P\{y_i = 1 \mid x_i\} = F(\eta)$$

Dabei ist $F()$ die Verteilungsfunktion der logistischen Verteilung.



Der Regressor X wird also zunächst linear transformiert und dann in $F()$ eingespeist. Damit liegt Y zwischen 0 und 1.

Theorie Nachtrag

Optisch liegen beide Verteilungsfunktionen nahe beieinander. Deshalb überrascht das Folgende nicht:

Unterschiede zwischen Probit und Logit

Gestalt der Verteilung ist leicht unterschiedlich, insbesondere am Rand. Dies merkt man ggf. bei sehr grossen Stichproben, die dann u U auch den Rand abdecken

Die Schätzwerte für die Modellparameter im Logit Modell sind um einen Faktor von ca. 1,8 grösser als im Probit Modell, was an der unterschiedlichen Skalierung der Modelle liegt

Gemeinsamkeiten zwischen Probit und Logit

Praktisch führen beide zu ähnlichen Ergebnissen

Beide werden mit ML geschätzt und beidesmal bewirkt die Konkavität der llf dass es nur ein Maximum gibt

Theorie Nachtrag

Gründe für die Fokussierung auf Logit

Für das Logit Modell lassen sich viele Berechnungen einfacher durchführen und bestimmte wichtige Eigenschaften exakt zeigen:

In der Berufserfahrung des Dozenten mit Ratingsystemen spielte nur das Logit Modell eine Rolle.

Sie wollen Kreditausfälle vorhersagen. Leider enthält Ihr Datensatz nur 0 und keine 1 = Ausfall. Wieviel können Sie lernen?

Ein wichtiges Thema dabei ist die Unausgewogenheit der Stichprobe. Es gibt oft zu wenige „Ausfälle“. Schröder (2002, 379) weist darauf hin, dass mind. 5% „Ausfälle“ vorhanden sein sollten.

Problematik wie beim Importance Sampling bei der Monte Carlo Bewertung von Derivaten. Lösungstechnik analog und komfortabel bei Logit Modell.

Fallstudie Rating

Modellgüte & Deployment

Ausführen Step 4 Coding GML_03_02 rating.R ergibt eine **Genauigkeit von 83,17%**.


Welchen Mehrwert in der Genauigkeit sehen Sie?

Dies motiviert eine Nutzung des Modells zur Klassifikation neuer Firmenkunden

Ausführen Step 5 Coding GML_03_02 rating.R

Was geschieht hier?

```
> #forecast Ig for a new "mean type" firm, BUT with double leverage-----
> newfirm = c(2*mean(booklev),mean(ebit),mean(logsales),mean(re),mean(wk)) #rep(0.5,5)
> newlinpred = newfirm %%% coef(fit1)[2:6]+coef(fit1)[1]
> levP = 1 / (1+exp(-newlinpred))#less typing than P/(1-P)
> levP
      [,1]
[1,] 0.158353
```



Ordered Logit

Verbeek (2015) behandelt auch Ordered Logit

Das Bsp in seinem Buch bezieht sich auf ein Corporate-Ratingsystem mit geordneten Ratingausprägungen

Abermals agiert eine latente Variable. Überschreitet sie bestimmte Klassengrenzen, so ändert sich das Rating. Es findet diesmal also eine Vergrößerung auf n Ausprägungen statt (vorher digital).

```
Call:
glm(formula = IG ~ booklev + ebit + logsales + re + wk

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-2.5840  -0.5411  -0.0491   0.5286   3.4210

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  -8.21432    0.86685  -9.476  < 2e-16 ***
booklev       -4.42727    0.77142  -5.739  9.52e-09 ***
ebit          4.35474    1.43992   3.024  0.00249 **
logsales      1.08159    0.09568  11.304  < 2e-16 ***
re            4.11611    0.48851   8.426  < 2e-16 ***
wk           -4.01249    0.74791  -5.365  8.10e-08 ***
```

```
> m <- polr(RatingFactor ~ booklev+ebit+logsales+re+wk, data = dfrm_clean, Hess=TRUE)
> summary(m)
Call:
polr(formula = RatingFactor ~ booklev + ebit + logsales + re +
      wk, data = dfrm_clean, Hess = TRUE)

Coefficients:
            Value Std. Error t value
booklev    -2.7517    0.47730  -5.765
ebit        4.7313    0.94476   5.008
logsales    0.9406    0.05884  15.984
re          3.5600    0.30229  11.777
wk         -2.5802    0.48263  -5.346

Intercepts:
    Value Std. Error t value
1|2 -0.3696  0.6332   -0.5837
2|3  4.8805  0.5208    9.3709
3|4  7.6259  0.5512   13.8361
4|5  9.8849  0.5916   16.7078
5|6 12.8829  0.6734   19.1315
6|7 14.7825  0.7841   18.8527
```

Ausführen Step 6 Coding GML_03_02 rating.R

Interpretieren Sie!

Ausblick

Multinomial Logit: Individuum wählt zwischen a Alternativen, wobei keine Ordnung zwischen A_i und A_j a priori herstellbar (Marketing Ökonometrie, s.u.)

- Weitere Beispiele:

- Kreditrückzahlung: Kunde kündigt Kredit vorzeitig oder Kunde zahlt Kredit wie vorgesehen ab oder Kunde kann Kredit nicht abbezahlen
- Spezialfall Kreditausfall: ja oder nein?
- Börsengang: ja oder nein?
- Feindliche Übernahme: ja oder nein?
- Dividendenausschüttung: ja oder nein?

Aspekte bei Multinomial Logit:

Conjoint Analyse: Regressoren erklären eine Rangordnung

Conditional Logit: Produktmerkmale als Regressoren

Mixed Logit: Produkt- und Kundenmerkmale als Regressoren

Welche Anwendungen kommen Ihnen für Ihre Praxis in den Sinn?

Rationale Ausübung einer Option? Quotierungspause während Handelstag?

Logit Modell

Nachbereitung

Arbeiten Sie Ch. 7 in Verbeek (2017) und
Kap. 4 in Gehrke (2022) nach.