

GML

Ökonometrie: ARIMA, GARCH

All models are wrong but some are useful, turn data into assets

Prof. Dr. Frank Lehrbass

Copyright

**© FOM Hochschule für Oekonomie & Management
gemeinnützige Gesellschaft mbH (FOM), Leimkugelstraße 6, 45141 Essen**


Dieses Werk ist urheberrechtlich geschützt und nur für den persönlichen Gebrauch im Rahmen der Veranstaltungen der FOM bestimmt.

Die durch die Urheberschaft begründeten Rechte (u. a. Vervielfältigung, Verbreitung, Übersetzung, Nachdruck) bleiben dem Urheber vorbehalten.

Das Werk oder Teile daraus dürfen nicht ohne schriftliche Genehmigung des Urhebers / der FOM reproduziert oder unter Verwendung elektronischer Systeme verarbeitet, vervielfältigt oder verbreitet werden. Dies schließt auch den Upload in soziale Medien oder andere digitale Plattformen ein.

- Wir verwenden die genannten Bücher und geben die im Text Quellen wie folgt an:
- Assenmacher, 2002, Einführung in die Ökonometrie, Oldenbourg
- Verbeek, 2017, Seite xx
- Schröder, 2002, dito (Esp. dicho)
- Danielsson, 2011, dito
- Gehrke, 2022, dito

- Wir betrachten zeitindexierte DGP. In der Ökonometrie fokussieren wir zeitdiskrete stochastische Prozesse (SP), d.h. Familien von ZV, die einen Index aus den natürlichen Zahlen haben so wie unsere üblichen Zeitreihen.
- Neu ist, dass wir in der Zeitreihe selbst eine Struktur vermuten
- D.h. wir wollen etwa den Ölpreis nicht durch andere Faktoren, sondern aus sich selbst heraus erklären
- Zeitreihen werden ab jetzt als Realisationen eines SP betrachtet
- Was könnten Gründe für eine „innere Uhr“ sein? 4
- Was sagt Ihnen „Hog/Pig Cycle“ & „BDI“?
- Wie realisierte sich dieser bei deutschen Investoren?



Baltic Dry Index 1985 – 2020

Stationarität

Ein stochastischer Prozess Y_t heisst stationär, wenn gilt:

$$E\{Y_t\} = \mu < \infty$$

$$V\{Y_t\} = E\{(Y_t - \mu)^2\} = \gamma_0 < \infty$$

$$\text{cov}\{Y_t, Y_{t-k}\} = E\{(Y_t - \mu)(Y_{t-k} - \mu)\} = \gamma_k, \quad k = 1, 2, 3, \dots$$

Synonym sagt man der SP ist kovarianzstationär oder „schwach stationär“. Wir benutzen nur das Adjektiv „stationär“.

Konkret: Sie haben ein Modell für Schweinepreise auf Daten von 1996 bis 2000 geschätzt. Nun modellieren Sie damit das Absatzpreisrisiko eines Bauern für die Jahre bis 2010.

Warum ist Stationarität die Grundlage Ihres Tuns?

Stationarität

Ein stochastischer Prozess Y_t heisst stationär, wenn gilt:

$$E\{Y_t\} = \mu < \infty$$

$$V\{Y_t\} = E\{(Y_t - \mu)^2\} = \gamma_0 < \infty$$

$$\text{cov}\{Y_t, Y_{t-k}\} = E\{(Y_t - \mu)(Y_{t-k} - \mu)\} = \gamma_k, \quad k = 1, 2, 3, \dots$$

Rückblick auf die Spuriousities:

$Y = \text{cumsum}(\text{rnorm}(80, 0, 0.05))$

Formal: Rekursion: $Y_t = Y_{t-1} + u_t$

Zur Erinnerung: u iid mit $E(u_t) = 0$ und $\text{Var}(u_t) = \sigma$

Wir nennen Y **Random Walk** und u **White Noise**. Damit kennen wir schon zwei wichtige SP.

Wie hoch war/ist σ im konkreten Beispiel?

Sind beide SP stationär?

Stationarität

Ein stochastischer Prozess Y_t heisst stationär, wenn gilt:

Es gilt: $Y_1 = Y_0 + u_1$

$$Y_2 = Y_1 + u_2 = Y_0 + u_1 + u_2$$

$$Y_3 = Y_2 + u_3 = Y_0 + u_1 + u_2 + u_3$$

...

Insgesamt gilt: $Y_t = Y_0 + \sum u_i$

Der Erwartungswert hiervon ist $E(Y_t) = E(Y_0) + E(\sum u_i) = E(Y_0)$, also unabhängig von t .

Aber $\text{var}(Y_t) = \text{var}(Y_0 + \sum u_i) = E(Y_0 + \sum u_i - Y_0)^2 = \sum E(u_i)^2 = \sum \sigma^2 = t\sigma^2$.

→ Die Varianz ist **zeitabhängig** und strebt für zunehmendes t gegen unendlich

Wie hoch war Y_0 im Bsp?

Was muss ich tun, um aus Y einen stationären SP zu machen?

$$E\{Y_t\} = \mu < \infty$$

$$V\{Y_t\} = E\{(Y_t - \mu)^2\} = \gamma_0 < \infty$$

$$\text{cov}\{Y_t, Y_{t-k}\} = E\{(Y_t - \mu)(Y_{t-k} - \mu)\} = \gamma_k, \quad k = 1, 2, 3, \dots$$

Stationarität

Ein stochastischer Prozess Y_t heisst stationär, wenn gilt:

Es gilt:

$$Y_t = Y_{t-1} + u_t$$

Beidseitiges Abziehen von Y_{t-1} führt zu:

$$\Leftrightarrow \Delta Y = Y_t - Y_{t-1} = u_t$$

$$E\{Y_t\} = \mu < \infty$$

$$V\{Y_t\} = E\{(Y_t - \mu)^2\} = \gamma_0 < \infty$$

$$\text{cov}\{Y_t, Y_{t-k}\} = E\{(Y_t - \mu)(Y_{t-k} - \mu)\} = \gamma_k, \quad k = 1, 2, 3, \dots$$

Ist white noise stationär?

Warum haben wir das CAPM auf Renditebasis und nicht auf Kursen geschätzt?

Zur Überprüfung der Stationarität gibt es Testverfahren. Details nachlesen bei Gehrke (2022, 363ff).

Augmented Dickey-Fuller-Test (ADF-Test)

- Um zusätzlich einen Zeittrend zu berücksichtigen, wird von einem erweiterten Modell ausgegangen (Schröder, 2002, 292):

$$\Delta Y_t = \alpha + \beta t + \delta Y_{t-1} + \beta_1 \Delta Y_{t-1} + \beta_2 \Delta Y_{t-2} + \dots + \beta_p \Delta Y_{t-p} + u_t$$

- Es handelt sich um die Gleichung des einfachen DF, wo u.a. das verzögerte Y beidseitig abgezogen wurde. Weitere Details bei Schröder (2002, 268).
- Basierend auf diesem erweiterten Modell wird der Dickey-Fuller-Test genauso wie im einfachen Fall durchgeführt, d. h., dieses Modell wird über eine OLS-Regression geschätzt, die τ -Statistik berechnet und mit dem zugehörigen tabellarisierten kritischen Wert verglichen.

Phillips-Perron-Test (PP-Test)

Bei ADF und PP lautet die Nullhypothese **keine Stationarität**

Kwiatkowski-Phillips-Schmidt-Shin-Test (KPSS-Test)



Im Gegensatz zu den beiden bisher vorgestellten Tests lautet die Nullhypothese **Stationarität**. Wird also H_0 verworfen, so ist die Zeitreihe nicht stationär.

Fallstudie Stahlaktien

thyssenkrupp

Ausführen Step 1 in GML_04_02 equities.R

Welche der beiden Zeitreihen ist stationär?



Fallstudie Stahlaktien

thyssenkrupp

Ausführen Step 2 in GML_04_02 equities.R

Wir haben nur 100 Datensätze. Deshalb erhöhen wir das Signifikanzniveau auf 10%

Was machen wir bei einer Mrd. Stipo Umfang?

Was sagen die Tests zu **Kurs** von TK?

Überprüfen Sie eigenständig Salzgitter (SG)!

```
> length(TK)
[1] 101
> TS = TK
>
> # Apply usual tests
> adf.test(TS)#H0 Non-stat
```

Augmented Dickey-Fuller Test

```
data: TS
Dickey-Fuller = -2.1513, Lag order = 4, p-value = 0.514
alternative hypothesis: stationary
```

```
> pp.test(TS)
```

Phillips-Perron Unit Root Test

```
data: TS
Dickey-Fuller Z(alpha) = -9.3001, Truncation lag parameter = 4, p-value = 0.5767
alternative hypothesis: stationary
```

```
> kpss.test(TS)#H0 Stat
```

KPSS Test for Level Stationarity

```
data: TS
KPSS Level = 1.475, Truncation lag parameter = 4, p-value = 0.01
```

```
Warning message:
In kpss.test(TS) : p-value smaller than printed p-value
```

Fallstudie Stahlaktien

thyssenkrupp

Ausführen Step 3

```
> #make sure same degree of integration = I(1)
> # Apply usual tests TK:
> TS = diff(TK)
> adf.test(TS)#H0 Non-stat
```

Augmented Dickey-Fuller Test

```
data: TS
Dickey-Fuller = -4.4152, Lag order = 4, p-value = 0.01
alternative hypothesis: stationary
```

```
Warning message:
In adf.test(TS) : p-value smaller than printed p-value
> pp.test(TS)
```

Phillips-Perron Unit Root Test

```
data: TS
Dickey-Fuller Z(alpha) = -106.84, Truncation lag parameter = 3, p-value = 0.01
alternative hypothesis: stationary
```

```
Warning message:
In pp.test(TS) : p-value smaller than printed p-value
> kpss.test(TS)#H0 Stat
```

KPSS Test for Level Stationarity

```
data: TS
KPSS Level = 0.074314, Truncation lag parameter = 4, p-value = 0.1
```

```
Warning message:
In kpss.test(TS) : p-value greater than printed p-value
```

Was sagen die Tests zu den **Kursdifferenzen** von TK und SG?

```
> # Apply usual tests SG:
> TS = diff(SG)
> adf.test(TS)#H0 Non-stat
```

Augmented Dickey-Fuller Test

```
data: TS
Dickey-Fuller = -4.4483, Lag order = 4, p-value = 0.01
alternative hypothesis: stationary
```

```
Warning message:
In adf.test(TS) : p-value smaller than printed p-value
> pp.test(TS)
```

Phillips-Perron Unit Root Test

```
data: TS
Dickey-Fuller Z(alpha) = -112.56, Truncation lag parameter = 3, p-value = 0.01
alternative hypothesis: stationary
```

```
Warning message:
In pp.test(TS) : p-value smaller than printed p-value
> kpss.test(TS)#H0 Stat
```

KPSS Test for Level Stationarity

```
data: TS
KPSS Level = 0.050905, Truncation lag parameter = 4, p-value = 0.1
```

```
Warning message:
In kpss.test(TS) : p-value greater than printed p-value
> #confirmed
```

Integrierte Zeitreihen

- Wird eine Zeitreihe Y_t insgesamt d mal einer Differenzenbildung unterzogen, bis sie stationär ist, so heißt sie integrierte Zeitreihe der Ordnung d .
Notation: $Y_t \sim I(d)$.
- Ist eine Zeitreihe Y_t stationär, ohne dass Differenzenbildungen erforderlich sind, so heißt sie integrierte Zeitreihe der Ordnung 0, $Y_t \sim I(0)$.
- Was haben wir wiederholt gemacht, um einen Prozess zu bekommen, der stationär ist bzw „in der Box bleibt“?
- Welchen Integrationsgrad hat ein Prozess der in der Box bleibt?
- Was gilt für die Kurszeitreihen TK und SG? Sie sind $I(\text{xxx})$, mit $\text{xxx} = ?$

Kointegration

Kointegration

- Das Spurious Regression Phänomen tritt auf, wenn ein Regressionsmodell zwischen zwei nicht-stationären Zeitreihen spezifiziert wird.
- Teilen die beiden stochastischen Trends jedoch einen gemeinsamen Trend, d. h., gilt für zwei nicht-stationäre Random Walks X_t und Y_t , dass $Y_t = \beta_1 + \beta_2 \cdot X_t + u_t$, dann ist die resultierende Regression zulässig und nicht spurious.

Definition: Kointegration

Zwei nicht-stationäre stochastische Prozesse X_t und Y_t heißen kointegriert, wenn es ein β_2 gibt, so dass der stochastische Prozess $Y_t - \beta_2 \cdot X_t$ stationär ist (d. h. die Linearkombination zweier nicht-stationärer Prozesse ist stationär).

WICHTIG: Deshalb sollte man nicht sofort Differenzen auf Kursen/Preisen bilden, sondern mit Bedacht vorgehen! Auch in Niveaubetrachtung kann Wert liegen!! Spread Trading!!! Welche Spreads kennen Sie?

Beispiele:

- Saldobestände zwischen Wareneingängen und Warenausgängen in einem Supermarkt sind stationär, die Wareneingänge und Warenausgänge sind kointegriert.
- Einnahmen und Ausgaben eines Haushalts sind kointegriert
- Aktienkurse verwandter Unternehmen-> **folgende Folien**

Engle-Granger Test und Phillips-Ouliaris Test auf Kointegration

- Zwei nicht-stationäre stochastische Prozesse X_t und Y_t heißen kointegriert, wenn es ein β_2 gibt, sodass der stochastische Prozess $Y_t - \beta_2 \cdot X_t$ stationär ist (d. h., die Linearkombination zweier nicht-stationärer Prozesse ist stationär).
- Die Grundidee der Tests auf Kointegration ist nun:
 - Schätze ein lineares Regressionsmodell an: $Y_t = \beta_1 + \beta_2 \cdot X_t + u_t$
 - Berechne die Residuen
 - Wende mind. einen Stationaritätstest auf die geschätzten Residuen an. Sind die Residuen stationär, dann sind die beiden Random Walks X_t und Y_t kointegriert.
- Diese Grundidee geht auf **Engle/Granger (1987)** zurück, die auch die kritischen Werte für verschiedene Testniveaus bestimmt haben.
- **Phillips/Ouliaris (1990)** konnten schließlich zeigen, dass dieser Test asymptotisch äquivalent zu einem anderen Unit Root Test von Phillips ist, in R heißt dieser Test deshalb auch Phillips-Ouliaris-Test.

Fallstudie Stahlaktien

Thyssenkrupp/Salzgitter

Ausführen Step 4

Was uns die Engle-Granger Reg.?

```
> #check a la Engle Granger
> reg = lm(SG ~ TK)
> summary(reg)
```

```
Call:
lm(formula = SG ~ TK)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-5.2570 -1.0381  0.0349  0.9835  4.6196
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  32.9719     2.8195  11.694 < 2e-16 ***
TK           0.7670     0.1216   6.309 7.94e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 1.959 on 99 degrees of freedom
Multiple R-squared:  0.2867,    Adjusted R-squared:  0.2795
F-statistic: 39.8 on 1 and 99 DF,  p-value: 7.938e-09
```

```
> TS = resis
> adf.test(TS)#H0 Non-stat
```

Augmented Dickey-Fuller Test

```
data: TS
Dickey-Fuller = -3.3387, Lag order = 4, p-value = 0.06854
alternative hypothesis: stationary
```

```
> pp.test(TS)
```

Phillips-Perron Unit Root Test

```
data: TS
Dickey-Fuller Z(alpha) = -14.602, Truncation lag parameter = 4, p-value = 0.2685
alternative hypothesis: stationary
```

```
> kpss.test(TS)#H0 Stat
```

KPSS Test for Level Stationarity

```
data: TS
KPSS Level = 0.49953, Truncation lag parameter = 4, p-value = 0.04177
```


Fallstudie Stahlaktien


Thyssenkrupp/Salzgitter

Ausführen Step 4

Wir unterstellen aus pädagog. Gründen, dass beide Zeitreihen kointegriert sind.

Welche kfm. Überlegungen unterstützen dies? Bilanzanalyse!

Wie würde man den Spread traden?



Fallstudie Stahlaktien

Thyssenkrupp/Salzgitter

Fokus auf die ersten Residuen:

Handelstag beginnt mit SG = 48,31 EUR. Nach GG Beziehung hätten es aber $0,76 \cdot 20,78 + 32,97 = 48,76$ EUR sein müssen => $Y - \hat{Y}$ = Residuum = negativ!

Nutze Mean Reversion of Spread!


SG ist zu billig=>long
TK zu teuer=>short

Nimm Position nah genug bei Eröffnungskurs
Liquidiere am nächsten Tag zum Opening

SG: 48,7-48,31 = 0,39 EUR Gewinn
TK: 20,78-20,90 = -0,12 Verlust
=> Saldo: 0,27 Gewinn
--> bei Halten bis Tag 6 noch grösser ...

```
head(cbind(TK,SG))
```

##		TK	SG
##	[1,]	20.775	48.305
##	[2,]	20.900	48.700
##	[3,]	21.440	49.250
##	[4,]	21.245	50.150
##	[5,]	21.580	51.120
##	[6,]	21.900	52.400



Fallstudie Stahlaktien

Thyssenkrupp/Salzgitter

Ausführen Step 5

Wir machen aus pädagog. Gründen einen weiteren Test

Welchen „Komfort“ (Gefühl von Sicherheit) würden Sie erwarten, ehe Sie den Spread traden?

```
> #noch ein Kointegrationstest: H0 not cointegrated.
> po.test(as.matrix(cbind(TK,SG)))

      Phillips-Ouliaris Cointegration Test

data:  as.matrix(cbind(TK, SG))
Phillips-Ouliaris demeaned = -0.5108, Truncation lag parameter = 1, p-value = 0.15

Warning message:
In po.test(as.matrix(cbind(TK, SG))) : p-value greater than printed p-value
>
> #a final word
> egcm(SG,TK)#use this also in live
Y[i] = 0.3738 X[i] + 4.1747 + R[i], R[i] = 1.0000 R[i-1] + eps[i], eps ~ N(0, 0.2610^2)
      (0.0593)      (3.0113)              (0.0197)

R[101] = 2.3663 (t = 1.739)

WARNING: X and Y do not appear to be cointegrated.
```

Voraussetzung der Kointegration - Vertiefung

- **Die Zeitreihen Y und X müssen dabei denselben Integrationsgrad haben!** (hierzu Assenmacher, 2002, 281)
- Bei einer Linearkombination von Zeitreihen kann man verschiedene Grade haben. Dann ist der höchste Integrationsgrad bestimmend. Hierzu folgt eine Tabelle weiter unten.
- Für einfache Regressionsmodelle gilt generell: Die Integrationsgrade von Regressor und Regressand müssen übereinstimmen
- **Für Regressionsmodelle mit mehreren Regressoren gilt generell: Der Integrationsgrad des Regressanden darf nicht von denen der Regressoren überschritten werden** (hierzu Assenmacher, 2002, 286)
- Hat man ein mehrdimensionales X dann muss mit dem Johansen Verfahren auf Kointegration geprüft werden (hierzu Assenmacher, 2002, 286ff)

Kointegration

Eigenschaften integrierter Zeitreihen und Effekt auf Regression

Betrachte die Schätzgleichung $Y_t = a + b X_t + \varepsilon_t$.

Dann ergibt sich für Y's Integrationsgrad folgendes und es gilt:

X	ε	Y	Was tun?
I(0)	I(0)	I(0)	Normale Regression
I(0)	I(1)	I(1)	Fehlspezifikation
I(1)	I(1)	I(1)	Auf Differenzen normale Reg.
I(1)	I(0)	I(1)	Kointegrationsfall

Wie könnte man die Residualanalyse nun auch noch interpretieren?

Was meint I(Resis)?

Motivation

Wir betrachten tägliche Änderung in **log** USD/EUR (log returns aus Investment in EUR) wie in Verbeek (2017, 340)

Vorteil der Logarithmierung

Varianzstabilisierung


Egal, ob Dynamik in Mengen- oder Preisnotierung untersucht wird

$$\rightarrow \log(1/S) = 0 - \log(S)$$

Ausführen Step 1 in GML_04_03 usdeur.R

Interpretieren Sie den Chart!

Können Sie Inso. Lehman Bros erkennen?



Motivation



Wir betrachten 2 ACF

Interpretieren Sie die Charts!

Macht Trading auf Basisi
technischer Analyse Sinn?

Was gilt bzgl. Vola Trading?

Welche stilisierten Fakten
erkennen Sie (wieder)?



```
> summary(FX)
      Min.    1st Qu.    Median      Mean   3rd Qu.     Max.
-4.735441 -0.380585  0.008172  0.004693  0.393003  4.204134

> kurtosis(FX)
[1] 2.588295
attr(,"method")
[1] "excess"

> skewness(FX)
[1] 0.1037974
attr(,"method")
[1] "moment"
```

Stylized Facts

- “1. Financial return distributions are leptokurtotic, that is they have heavier tails and a higher peak than a normal distribution.
 2. Skewed returns
 3. Squared returns have significant autocorrelation, i.e. volatilities of market factors tend to cluster” (Engle & Manganelli, 2001)
- (and as fourth fact negligible mean returns)

Modellansatz

“The GARCH forecast variance is a weighted average of three different variance forecasts. One is a constant variance that corresponds to the long run average. The second is the forecast that was made in previous period. The third is the new information that was not available when the previous forecast was made. This could be viewed as a variance forecast based on one period of information. The weights on these three forecasts determine how fast the variance changes with new information and how fast it reverts to its long run mean” (Engle, 2003).

Conditional Heteroskedasticity (CH) is the name of the game!

Aus welchen drei Elementen wird die konditionale Varianz erzeugt?

Modellansatz

“The GARCH forecast variance is a weighted average of three different variance forecasts. One is a constant variance that corresponds to the long run average. The second is the forecast that was made in previous period. The third is the new information that was not available when the previous forecast was made. This could be viewed as a variance forecast based on one period of information. The weights on these three forecasts determine how fast the variance changes with new information and how fast it reverts to its long run mean” (Engle, 2003).

$$y_t = \sigma_t z_t$$

In diesem Sinne modellieren wir die Log>Returns y_t :

$$\sigma_t^2 = \omega + \alpha y_{t-1}^2 + \beta \sigma_{t-1}^2$$

ARCH- und G.- Term

wobei z_t die Innovation der y -Zeitreihe und i.i.d. verteilt ist mit $E(z_t)=0$

Als Verteilungen betrachten wir nachfolgend zwei Praxisrelevante: Normalverteilung und Student-t

Identifizieren Sie die drei Elemente im Text in den Gleichungen!

Wie sieht ein GARCH(p,q) aus?

Wie ist $E_{t-1}(y_t)$? Realistisch?

Konsequenzen

Die unbedingte Varianz lautet:

$$\sigma^2 = \frac{\omega}{1 - \alpha - \beta}$$

Was muss gelten, damit die unbedingte Varianz positiv ist?

$$\sigma_t^2 = \omega + \alpha y_{t-1}^2 + \beta \sigma_{t-1}^2.$$

Welche Bedingungen müssen erfüllt sein, damit die bedingte Varianz positiv ist?

Stationarität von y ist gegeben, wenn $\alpha + \beta < 1$.

Wir werden diese Parametersumme deshalb je Anwendung prüfen müssen. Wenn >1 so ist die Varianz undefiniert (negativer Nenner!). Wenn $=1$ so ist die Varianz unendlich!

In beiden Fällen liegt kein stationäres Modell vor!

Das Modell würde sich also in der Zeit ändern und ist damit unbrauchbar!

Wir vertiefen dies später.

Konsequenzen

Die unbedingte Varianz lautet:

$$\sigma^2 = \frac{\omega}{1 - \alpha - \beta}$$

Was muss gelten, damit die unbedingte Varianz positiv ist?

$$\sigma_t^2 = \omega + \alpha y_{t-1}^2 + \beta \sigma_{t-1}^2.$$

Welche Bedingungen müssen erfüllt sein, damit die bedingte Varianz positiv ist?

Stationarität von y ist gegeben, wenn $\alpha + \beta < 1$.

Eigenschaften

Stationarität von y ist gegeben, wenn $\alpha + \beta < 1$.

Wir werden diese Parametersumme deshalb je Anwendung prüfen müssen. Wenn > 1 so ist die Varianz undefiniert (negativer Nenner!). Wenn $= 1$ so ist die Varianz unendlich!

In beiden Fällen liegt kein stationäres Modell vor!

Das Modell würde sich also in der Zeit ändern und ist damit unbrauchbar!

Wir vertiefen dies später.

Auch wenn die Verteilung für z dünnschwänzig ist ($z \sim$ Normalverteilung), führt schon ein ARCH(1) ($\rightarrow$ setze $\beta = 0$ im GARCH) zur Kurtosis > 3 bei y , wenn $3\alpha^2 < 1$ (Danielsson, 2011, 37). Damit sind die Fakten 1 und 3 modelliert.

Skewness kann etwa durch Wahl einer schiefen Verteilung für z erzeugt werden.

Eigenschaften

Stationarität ist gegeben, wenn gilt:

$$\sum_{i=1}^q \alpha_i + \sum_{j=1}^p \beta_j < 1$$

Die bedingte Varianz $\text{Var}(Y_t)$ ist positiv, wenn gilt:

- $\omega > 0$
- $\alpha_i \geq 0$ für $i = 1, \dots, q$
- $\beta_j \geq 0$ für $j = 1, \dots, p$

Die langfristige (unbedingte) Varianz ergibt sich aus

$$\sigma_L^2 = \frac{\beta_0}{1 - \sum_{i=1}^p \beta_i - \sum_{j=1}^q \alpha_j}$$

Der Koeffizient β_0 wurde zuvor mit ω bezeichnet.

Vorteile des GARCH Modell gegenüber dem ARCH-Modell

Insbesondere in Bezug auf Finanzmarktdaten kommen GARCH Modelle mit weniger Koeffizienten als ARCH Modelle aus und liefern daher meist bessere Schätzergebnisse. Oft reicht schon ein GARCH(1,1) Modell aus.

Beispiel für die Nutzung eines GARCH(1,1)-Modell im RiskManagement

$$\sigma_n^2 = 0,000002 + 0,13Y_{n-1}^2 + 0,86\sigma_{n-1}^2$$

Somit ergeben sich :

$$\beta_1 = 0,13 \quad \alpha_1 = 0,86 \quad \beta_0 = 0,000002$$

$$\sigma_L^2 = \frac{\beta_0}{1 - \beta_1 - \alpha_1} = \frac{0,000002}{1 - 0,13 - 0,86} = 0,0002$$

Langfristige Volatilität $\sqrt{\sigma_L^2} \approx 0,014 = 1,4\%$ pro Tag

Folgende Daten seien für den Tag $n - 1$ gegeben

Volatilität = 1,6%, Kurs sei um 1% gefallen

$$\sigma_n^2 = 0.000002 + 0.13 \cdot 0.01^2 + 0.86 \cdot 0.016^2 = 0.00023516$$

$$\sigma_n = 0.0153 = 1.53\% \text{ Volatilität pro Tag}$$

Für den Tag n würden wir somit am Tag $n-1$ den VaR mit einer 1,53% Vola rechnen, d.h. 24er Vola p.a. (1,53% mal Wurzel(250))

Fallstudie USD vs EUR

Wir wollen uns – ergänzend zur ACF - vergewissern, dass ein ARCH Effekt vorliegt

Ein statistischer Test auf einen ARCH-Effekt

- Sei $Y_t = \beta_0 + \beta_1 X_{1t} + \dots + \beta_k X_{kt} + u_t$ eine lineare Regression für eine Zeitreihe mit k unabhängigen Variablen. Wenn ein ARCH-Effekt vorliegt, dann gilt für die Varianz der Residuen u_t :

$$\text{Var}(u_t) = u_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \dots + \alpha_p u_{t-p}^2$$

- Liegt kein ARCH-Effekt vor, so sind alle $\alpha_i = 0$ für $i > 0$, d. h. zu testen ist die Nullhypothese

$$H_0: \alpha_1 = \dots = \alpha_p = 0.$$

- Diese Nullhypothese kann durch den F-Test der nachfolgenden Hilfsregression

$$u_t^2 = \alpha_0 + \alpha_1 \hat{u}_{t-1}^2 + \dots + \alpha_p \hat{u}_{t-p}^2 + \varepsilon$$

getestet werden, $\hat{u}_t$ bezeichnet dabei die geschätzten Residuen aus der eingangs definierten linearen Regression.

- Weiter gilt für das Bestimmtheitsmaß der Hilfsregression R^2 , dass nR^2 asymptotisch Chi-Quadrat-verteilt ist mit p Freiheitsgraden, d. h. für große Stichprobenumfänge n kann die Nullhypothese auch mit einem Chi-Quadrat-Test getestet werden.

Fallstudie USD vs EUR

Ausführen Step 2 in GML_04_03
usdeur.R

Interpretieren Sie!

```
> rt = residuals(olstest)
> rt = rt[-1]
> rt_1 = residuals(olstest)
> rt_1 = rt_1[-length(rt_1)]
>
> summary(lm(rt^2 ~ rt_1^2))
```

```
Call:
lm(formula = rt^2 ~ rt_1^2)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-0.7208 -0.4097 -0.2790  0.0541  21.6005
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.45059    0.01733   25.995 < 2e-16 ***
rt_1         0.10766    0.02583    4.169 3.15e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.9629 on 3084 degrees of freedom
Multiple R-squared:  0.005603, Adjusted R-squared:  0.005281
F-statistic: 17.38 on 1 and 3084 DF, p-value: 3.148e-05
```

Beispiel für den ARCH-Test für DAX-Renditen

- Für die DAX-Tagesschlusskurse Y_t seien die Tagesrenditen r_t wieder definiert als $r_t = Y_t / Y_{t-1}$. Die zugehörige lineare Regression lautet:

$$r_t = \beta_0 + u_t,$$

d. h. die DAX-Tagesrendite hängt lediglich von einem Residuum ab.

- Für einen Test auf einen ARCH(1)-Effekt sind zunächst mit der linearen Regression die Residuen $\hat{u}_t$ zu schätzen. Für diese geschätzten Residuen wird nun folgende Hilfsregression durchgeführt:

$$u_t^2 = \alpha_0 + \alpha_1 \hat{u}_{t-1}^2 + \varepsilon.$$

- Ist der Parameter α_1 signifikant von 0 verschieden, so liegt ein ARCH(1)-Effekt vor.

Fallstudie USD vs EUR

„In zahlreichen empirischen Untersuchungen hat sich gezeigt, dass die Beschränkung auf GARCH(1,1) ausreichend ist“ (Schröder, 2002, 322)

Informationstheoretische Argumente für Finanzmärkte stützen diese Erfahrung zusätzlich.

Wir schätzen nun zwei GARCH(1,1) Modelle. Eines mit standardnormalverteilten z und eines mit Student-t verteilten Innovationen.

Details zur Schätzmethode siehe Verbeek (2017, 338).

Fallstudie USD vs EUR

Ausführen Step 3 in GML_04_03 usdeur.R

Normal GARCH:

First Check

Welchen Wert für den Mittelwert von Y können wir unterstellen?

Was würde man andernfalls machen? Was meint Demeaning?

```
> fit0 <- garchFit(~garch(1,1),cond.dist = "norm", data=FX,include.mean = T, trace = FALSE)
> summary(fit0) #see Gehrke 2022 393ff
```

Title:
GARCH Modelling

Call:
garchFit(formula = ~garch(1, 1), data = FX, cond.dist = "norm",
include.mean = T, trace = FALSE)

Mean and Variance Equation:
data ~ garch(1, 1)
<environment: 0x00000145c1747bf8>
[data = FX]

Conditional Distribution:
norm

Coefficient(s):

mu	omega	alpha1	beta1
0.016653	0.001671	0.031369	0.965223

Std. Errors:
based on Hessian

Error Analysis:

	Estimate	Std. Error	t value	Pr(> t)
mu	0.0166525	0.0106787	1.559	0.1189
omega	0.0016710	0.0007214	2.316	0.0205 *
alpha1	0.0313693	0.0042463	7.387	1.5e-13 ***
beta1	0.9652228	0.0045898	210.300	< 2e-16 ***

Fallstudie USD vs EUR

Ausführen Step 3 in GML_04_03 usdeur.R

Normal GARCH refined:

Standardised Residuals Tests:

			Statistic	p-Value
Jarque-Bera Test	R	Chi^2	127.6274	0
Shapiro-Wilk Test	R	W	0.9940898	7.408935e-10
Ljung-Box Test	R	Q(10)	3.939719	0.9500254
Ljung-Box Test	R	Q(15)	13.82707	0.5386831
Ljung-Box Test	R	Q(20)	15.02977	0.7747018
Ljung-Box Test	R^2	Q(10)	5.076126	0.886035
Ljung-Box Test	R^2	Q(15)	6.728588	0.9647482
Ljung-Box Test	R^2	Q(20)	8.881579	0.9842387

Sind die Bedingungen für eine positive bedingte Varianz und Stationarität erfüllt?

Diagnostik: Ist standardisiertes Resi normalverteilt?

Ljung Box: H0 Autokorr = 0. Fazit?

```
> summary(fit1) #see Gehrke 2022 393ff

Title:
  GARCH Modelling

Call:
  garchFit(formula = ~garch(1, 1), data = FX, cond.dist = "norm",
    include.mean = FALSE, trace = FALSE)

Mean and Variance Equation:
  data ~ garch(1, 1)
<environment: 0x00000145c25b0908>
 [data = FX]

Conditional Distribution:
  norm

Coefficient(s):
      omega      alpha1      beta1
0.0016829  0.0310095  0.9655447

Std. Errors:
  based on Hessian

Error Analysis:
      Estimate Std. Error t value Pr(>|t|)
omega  0.0016829  0.0007237   2.326   0.02 *
alpha1 0.0310095  0.0041855   7.409 1.27e-13 ***
beta1  0.9655447  0.0045410 212.629 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Log Likelihood:
-2971.618      normalized: -0.9626232
```

Fallstudie USD vs EUR

Ausführen Step 4 in GML_04_03 usdeur.R

Student t GARCH:

Sind die Bedingungen für eine positive bedingte Varianz und Stationarität erfüllt?

Was mutet seltsam an?

Einordnung: Für Commodity & Financial Markets df 6-10

```
> summary(fit2)

Title:
  GARCH Modelling

Call:
  garchFit(formula = ~garch(1, 1), data = FX, cond.dist = "std",
    include.mean = FALSE, include.delta = FALSE, trace = FALSE)

Mean and Variance Equation:
  data ~ garch(1, 1)
<environment: 0x00000145bffb61b98>
 [data = FX]

Conditional Distribution:
  std

Coefficient(s):
      omega      alpha1      beta1      shape
0.001979    0.031577    0.964447    10.000000

Std. Errors:
  based on Hessian

Error Analysis:
      Estimate Std. Error  t value Pr(>|t|)
omega 1.979e-03  8.599e-04    2.301   0.0214 *
alpha1 3.158e-02  4.900e-03    6.444 1.16e-10 ***
beta1  9.644e-01  5.352e-03   180.217 < 2e-16 ***
shape 1.000e+01  1.464e+00    6.829 8.56e-12 ***
```

Fallstudie USD vs EUR

Ausführen Step 6 in GML_04_03 usdeur.R



Student t GARCH:

```
std_res1 <- fit2@residuals/fit2@sigma.t #this standardizes the residuals to mean = 0, s=1
x11()
plot(std_res1, type = 'l')

kernel_den = density(std_res1)
x11()
plot(kernel_den, main="Standardized residuals vs Student t Density", xlab = " ")
x <- seq(min(kernel_den$x),max(kernel_den$x),length = 1000)
std_den = dstd(x,mean = mean(std_res1),sd = sd(std_res1), nu = Shape)
lines(x,std_den,type="l",col="red")
```

Was machen wir hier?

Was halten Sie von der Verteilungsan





Fallstudie USD vs EUR

Ausführen Step 6 in GML_04_03
usdeur.R

Student t GARCH:

Wieviel serielle Struktur haben wir
übersehen?



GARCH Modell – Praktische Nutzung

- Wir betrachten beide Varianten im Vergleich und runden die geschätzten Parameter für leichteres Rechnen
- Die Standardabweichung der Renditen auf Tagesbasis sei s
- **Normal GARCH(1,1)** sei geschätzt als: $s_t^2 = 0.002 + 0.031 y_{t-1}^2 + 0.966 s_{t-1}^2$
- Die Vorhersage für heute war 1% und die heutige Rendite sei -20%. Damit ergibt sich für morgen ein s von:
- $0.002 + 0.031 (-0.2)^2 + 0.966 0.01^2 = 0.003$. Wurzel daraus ergibt $s = 0.058$.
- Die heute erfolgte starke Marktbewegung führt somit zur Erwartung hoher Nervosität im Markt. Entsprechend steigt der VaR 99%. Bei Normalverteilung gilt in R $qnorm(0.99) = 2.326348$, gerundet 2.326. Bekanntermaßen ist der VaR 99% also $E(y) + 2.326 * s$. Auf tgl. Basis kann $E(y) = 0$ angenommen werden, d.h. passend zum geschätzten GARCH Modell (Danielsson, 2011, 105). Der VaR ergibt sich somit als $+ 2.326 * 0.058 = 0.135$. Der 1%-worst-case für die USD Position beträgt somit knapp 14%.
- Analog kann mit dem Student-t Modell gearbeitet werden, wo $df = 10$ geschätzt wurde. Man beachte, dass $qt(0.99, 10) = 2.763769$, gerundet 2.764. Auch die Vorhersage für s ist anders.
- Skalierung auf weitere Horizonte wie üblich
- Justagen um Modellrisikofaktoren oder Stressphasen sind ebenfalls mgl.

Abgrenzung/Einführung

Zu den stilisierten Fakten zählt, dass Finanzmarktrenditen eine ACF aufweisen, die sofort auf die Null sinkt. D.h. technische Analyse ist bei Tages-, Wochen Renditen aussichtslos.

Auf realwirtschaftlichen Märkten kann es jedoch Zyklen geben. Und sei es durch Aussaat und Ernte. Bei VWL Zeitreihen gibt es ebenfalls solche Zyklen, denn der August ist alljährlich Ferienmonat.

Deshalb wollen wir die Modellierung solcher Phänomene im Ansatz anschauen. Den GARCH könnten wir danach als ARMA(1,1) für die quadrierten Renditen begreifen. Dies zeigt nur eine Querverbindung auf.

ARIMA steht für AutoRegressiveIntegratedMovingAverage:

Das I() kennen wir schon. Deshalb ab jetzt nur die beiden Komponenten AR und MA.

AR

Ein autoregressiver Prozess ist dieser:

$$Y_t = \delta + \theta Y_{t-1} + \varepsilon_t,$$

ε_t steht für eine seriell unkorrelierte Innovation mit Erwartungswert Null und konstanter Varianz (= white noise).

Der Name Innovation ist im Zusammenhang mit ARIMA wörtlich zu nehmen. Zufällige Einflüsse treiben die Dynamik des autoregressiven Prozesses erster Ordnung, kurz AR(1).

Wie sieht ein AR(2) für Y aus?

Nehmen Sie den Schweinezyklus (4 M Tragezeit): Was ist das maximale Lag aus theoretischer Sicht?

AR(1)

$$Y_t = \delta + \theta Y_{t-1} + \varepsilon_t,$$

Die Verteilung der Y wird durch die Autokovarianz charakterisiert.

Die k-te Autokovarianz wird bezeichnet mit:

$$\gamma_k = \text{cov}\{Y_t, Y_{t-k}\}$$

Für den AR(1) gilt konkret:

$$\text{cov}\{Y_t, Y_{t-k}\} = \theta^k \frac{\sigma^2}{1 - \theta^2}.$$

Solange θ verschieden von Null ist, sind zwei Y_t miteinander korreliert.

Je weiter weg beide Y_t voneinander sind, umso schwächer ist dieser Zusammenhang - solange θ kleiner eins.

Stationär für $|\theta| < 1$.

Wie heisst der Prozess wenn $\theta = 1$?

Autokorrelationsfunktion

Wie üblich standardisiert man die Autokovarianzen auf das Intervall -1 bis 1

$$\rho_k = \frac{\text{cov}\{Y_t, Y_{t-k}\}}{V\{Y_t\}} = \frac{\gamma_k}{\gamma_0}.$$


Die Autokorrelationsfunktion (ACF) als Funktion von k nennt man auch “Korrelogramm”.

Sie charakterisiert das Gedächtnis des Zufallsprozesses Y_t (=stochastischer Prozess). Konkret wird deutlich, wie lange ein Schock nachwirkt.

Wie wird die ACF für den AR(1) verlaufen?

Autokorrelationsfunktion

Wie wird die ACF für $\theta = -0.6$ verlaufen?



MA(1)

$$Y_t = \mu + \varepsilon_t + \alpha \varepsilon_{t-1}.$$

Der Moving Average Prozess verhält sich anders. Nur zum Lag $k=1$ gibt es Autokovarianz $\neq 0$. Sonst nicht.

Die ACF sieht wie folgt aus: $\rho_1 = \alpha/(1+\alpha^2)$, $k>1$ $\rho_k = 0$ (Verbeek, 2017, 292)

Man kann AR und MA kombinieren.

Schreiben Sie die Bestimmungsgleichung für einen ARMA(1,1) und einen ARMA(12,5) an die Tafel

Wie wird die Autokorrelationsfunktion aussehen?

MA(1)





Figure 8.2 First-order moving average processes: data series and autocorrelation functions.


Fallstudie ARIMA

- Wir analysieren tägliche Verkaufszahlen für überbackene Käsebrötchen, da es eins der meistverkauften Produkte ist, an allen Wochentagen verkauft wird und bis zum Ende der Verkaufsperiode für den Kunden verfügbar sein soll
- Fehlprognosen des Absatzes sind hier also besonders ärgerlich
- Wir lassen die Newsvendorthematik aussen vor und prüfen, wie weit wir mit ARIMA kommen



Fallstudie

- Wir analysieren tägliche Verkaufszahlen für überbackene Käsebrötchen, da es eins der meistverkauften Produkte ist, an allen Wochentagen verkauft wird und bis zum Ende der Verkaufsperiode für den Kunden verfügbar sein soll
- Die Zeitreihe des Absatzes weist deutliche Muster auf
- Zudem einen Zeittrend n. u.
- Wir überprüfen dies und etwaige Effekte durch COVID.
- Hierfür Dummy, der ab erstem Lockdown am 22.3.20 den Wert eins hat



- Ausführen von Zeilen 1-38 im Coding GML_04_01 buns.R
- Interpretieren Sie
- Machen die Ergebnisse Sinn?

```
> summary(lm(daten$AMOUNT~daycounter+covid))
```

Call:
lm(formula = daten\$AMOUNT ~ daycounter + covid)

Residuals:

Min	1Q	Median	3Q	Max
-37.492	-6.486	-2.282	3.982	72.804

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	38.1298196	0.4931076	77.326	< 2e-16	***
daycounter	-0.0019329	0.0004542	-4.255	2.18e-05	***
covid	-1.6309690	0.8037310	-2.029	0.0426	*

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.71 on 2223 degrees of freedom
Multiple R-squared: 0.02404, Adjusted R-squared: 0.02316
F-statistic: 27.38 on 2 and 2223 DF, p-value: 1.798e-12

- Ausführen von Zeilen 40-45 im Coding GML_04_01 buns.R
- Interpretieren Sie
- Was ist bei der Reg anders als sonst?
- Warum?
- An wieviel Tagen hat die Bäckerei geöffnet?
- Machen die Ergebnisse Sinn?
- Erklärt das Modell den Absatz?
- Was ist noch zu tun?

```
> summary(reg_final, digits = 4)
```

Call:

```
lm(formula = AMOUNT ~ daycounter + mon + tue + wed + thu + fri +  
    sat + sun + BOCHUM_TOTAL + KEMNADE_IN_FLAMMER + holiday +  
    covid + -1, data = daten)
```

Residuals:

Min	1Q	Median	3Q	Max
-71.320	-4.318	-0.254	4.067	55.569

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
daycounter	-0.0018968	0.0003447	-5.503	4.17e-08	***
mon	35.3335914	0.5657842	62.451	< 2e-16	***
tue	33.5728103	0.5642086	59.504	< 2e-16	***
wed	34.3420027	0.5644066	60.846	< 2e-16	***
thu	35.1827653	0.5675384	61.992	< 2e-16	***
fri	34.1390956	0.5669721	60.213	< 2e-16	***
sat	37.4061440	0.5660995	66.077	< 2e-16	***
sun	52.4756284	0.5658694	92.735	< 2e-16	***
BOCHUM_TOTAL	3.4435418	1.8326925	1.879	0.06038	.
KEMNADE_IN_FLAMMER	3.9289039	1.8494494	2.124	0.03375	*
holiday	20.1647763	1.0848763	18.587	< 2e-16	***
covid	-1.6576039	0.6101629	-2.717	0.00665	**

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.123 on 2214 degrees of freedom
 Multiple R-squared: 0.9529, Adjusted R-squared: 0.9527
 F-statistic: 3733 on 12 and 2214 DF, p-value: < 2.2e-16

- Ausführen von Zeilen 47-69 im Coding GML_04_01 buns.R
- Warum vergleichen wir nun diese beiden Tapeten?

```



      Estimate Std. Error t value Pr(>|t|)
daycounter -0.00189684 0.00034471 -5.5028 4.17e-08 ***
mon        35.33359141 0.56578417 62.4507 < 2.2e-16 ***
tue        33.57281027 0.56420862 59.5042 < 2.2e-16 ***
wed        34.34200271 0.56440657 60.8462 < 2.2e-16 ***
thu        35.18276529 0.56753844 61.9919 < 2.2e-16 ***
fri        34.13909557 0.56697212 60.2130 < 2.2e-16 ***
sat        37.40614402 0.56609955 66.0770 < 2.2e-16 ***
sun        52.47562837 0.56586943 92.7345 < 2.2e-16 ***
BOCHUM_TOTAL 3.44354181 1.83269248 1.8790 0.060382 .
KEMNADE_IN_FLAMMER 3.92890389 1.84944940 2.1244 0.033750 *
holiday     20.16477630 1.08487625 18.5872 < 2.2e-16 ***
covid      -1.65760385 0.61016294 -2.7167 0.006646 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> coeftest(reg_final,vcov=NeweyWest(reg_final))

t test of coefficients:

      Estimate Std. Error t value Pr(>|t|)
daycounter -0.00189684 0.00049729 -3.8143 0.0001403 ***
mon        35.33359141 0.73765012 47.9002 < 2.2e-16 ***
tue        33.57281027 0.68648967 48.9050 < 2.2e-16 ***
wed        34.34200271 0.64063042 53.6066 < 2.2e-16 ***
thu        35.18276529 0.68619331 51.2724 < 2.2e-16 ***
fri        34.13909557 0.69168672 49.3563 < 2.2e-16 ***
sat        37.40614402 0.68797429 54.3714 < 2.2e-16 ***
sun        52.47562837 0.78063815 67.2215 < 2.2e-16 ***
BOCHUM_TOTAL 3.44354181 2.05394542 1.6765 0.0937717 .
KEMNADE_IN_FLAMMER 3.92890389 2.36746915 1.6595 0.0971492 .
holiday     20.16477630 3.44124370 5.8597 5.329e-09 ***
covid      -1.65760385 0.92666501 -1.7888 0.0737862 .
```

- Ausführen von Zeilen 71-88 im Coding GML_04_01 buns.R
- Gibt es in den Resis noch Struktur?
- Wieviele Tage hat die Woche?



- Ausführen von Zeilen 90-95
- Interpretieren Sie
- Warum tun wir das?

```
> adf.test(resis)
```

Augmented Dickey-Fuller Test

```
data: resis
Dickey-Fuller = -8.3202, Lag order = 13, p-value = 0.01
alternative hypothesis: stationary
```

Warning message:

```
In adf.test(resis) : p-value smaller than printed p-value
> # Phillips-Perron (PP) Test
> pp.test(resis)
```

Phillips-Perron Unit Root Test

```
data: resis
Dickey-Fuller Z(alpha) = -2486.4, Truncation lag parameter = 8, p-value = 0.01
alternative hypothesis: stationary
```

Warning message:

```
In pp.test(resis) : p-value smaller than printed p-value
> # Kwiatkowski-Phillips-Schmidt-Shin (KPSS) Test
> kpss.test(resis)
```

KPSS Test for Level Stationarity

```
data: resis
KPSS Level = 0.23956, Truncation lag parameter = 8, p-value = 0.1
```

Warning message:

```
In kpss.test(resis) : p-value greater than printed p-value
```


- Ausführen von Zeilen 101-105
- Interpretieren Sie

```
> autofitarima
Series: resis
ARIMA(2,0,1) with zero mean

Coefficients:
      ar1      ar2      ma1
      0.9540  0.0142 -0.9186
s.e.  0.0283  0.0227  0.0189

sigma^2 estimated as 63.34:  log likelihood=-7774.47
AIC=15556.94  AICc=15556.95  BIC=15579.77
```

- Was machen wir hier?



- Ausführen von Zeilen 107-118
- Interpretieren Sie
- Ist Ockham unser Freund?

Model:
ARMA(2,1)

Residuals:

Min	1Q	Median	3Q	Max
-69.867	-4.110	-0.176	4.020	55.707

Coefficient(s):

	Estimate	Std. Error	t value	Pr(> t)	
ar1	0.95435	0.02793	34.17	<2e-16	***
ar2	0.01382	0.02265	0.61	0.542	
ma1	-0.91937	0.01833	-50.15	<2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Fit:

sigma^2 estimated as 63.28, Conditional Sum-of-Squares = 140682.1, AIC = 15555.77

>

> fitarma1 = arma(resis, order = c(1, 1), include.intercept = F)

> summary(fitarma1)#small change in para values, sign same, enjoy inside unit circle

Call:

arma(x = resis, order = c(1, 1), include.intercept = F)

Model:
ARMA(1,1)

Residuals:

Min	1Q	Median	3Q	Max
-69.8426	-4.1481	-0.1672	3.9916	55.6820

Coefficient(s):

	Estimate	Std. Error	t value	Pr(> t)	
ar1	0.96903	0.01138	85.16	<2e-16	***
ma1	-0.92079	0.01742	-52.87	<2e-16	***

- Ausführen von Zeilen 107-118
- Interpretieren Sie
- Ist Ockham unser Freund?
- Man könnte nun die Residuen ausmodellieren
 - GARCH / Lin Reg und GARCH zusammen
- Zum Abschluss der univariaten Betrachtung
- Gehen wir jedoch einen anderen Weg

```

Model:
ARMA(2,1)

Residuals:
      Min       1Q   Median       3Q      Max
-69.867  -4.110  -0.176   4.020  55.707

Coefficient(s):
      Estimate Std. Error t value Pr(>|t|)
ar1    0.95435    0.02793   34.17  <2e-16 ***
ar2    0.01382    0.02265    0.61   0.542
ma1   -0.91937    0.01833  -50.15  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Fit:
sigma^2 estimated as 63.28,  Conditional Sum-of-Squares = 140682.1,  AIC = 15555.77

>
> fitarma11 = arma(resis, order = c(1, 1), include.intercept = F)
> summary(fitarma11)#small change in para values, sign same, enjoy inside unit circle

Call:
arma(x = resis, order = c(1, 1), include.intercept = F)

Model:
ARMA(1,1)

Residuals:
      Min       1Q   Median       3Q      Max
-69.8426  -4.1481  -0.1672   3.9916  55.6820

Coefficient(s):
      Estimate Std. Error t value Pr(>|t|)
ar1    0.96903    0.01138   85.16  <2e-16 ***
ma1   -0.92079    0.01742  -52.87  <2e-16 ***

```


- Ausführen von Zeilen 155-169
- Nimm Y_{t-1} als Regressor auf
- Führt zu Endogenität und Verzerrung
- Was ändert sich?

```

              Estimate Std. Error t value Pr(>|t|)
daycounter    -0.0018968  0.0003447  -5.503 4.17e-08 ***
mon             35.3335914  0.5657842  62.451 < 2e-16 ***
tue             33.5728103  0.5642086  59.504 < 2e-16 ***
wed             34.3420027  0.5644066  60.846 < 2e-16 ***
thu             35.1827653  0.5675384  61.992 < 2e-16 ***
fri             34.1390956  0.5669721  60.213 < 2e-16 ***
sat             37.4061440  0.5660995  66.077 < 2e-16 ***
sun            52.4756284  0.5658694  92.735 < 2e-16 ***
BOCHUM_TOTAL     3.4435418  1.8326925   1.879 0.06038 .
KEMNADE_IN_FLAMMER 3.9289039  1.8494494   2.124 0.03375 *
holiday        20.1647763  1.0848763  18.587 < 2e-16 ***
covid          -1.6576039  0.6101629  -2.717 0.00665 **

Call:
lm(formula = AMOUNT[-1] ~ AMOUNT[-length(AMOUNT)] + daycounter[-1] +
    mon[-1] + tue[-1] + wed[-1] + thu[-1] + fri[-1] + sat[-1] +
    sun[-1] + BOCHUM_TOTAL[-1] + KEMNADE_IN_FLAMMER[-1] + holiday[-1] +
    covid[-1] + -1, data = daten)

Residuals:
    Min       1Q   Median       3Q      Max
-71.488  -4.213   -0.316    4.040   55.063

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
AMOUNT[-length(AMOUNT)]  0.075745  0.019732   3.839 0.000127 ***
daycounter[-1]          -0.001752  0.000346  -5.064 4.44e-07 ***
mon[-1]                 31.310928  1.189897  26.314 < 2e-16 ***
tue[-1]                 30.829721  0.909292  33.905 < 2e-16 ***
wed[-1]                 31.760977  0.876646  36.230 < 2e-16 ***
thu[-1]                 32.531673  0.892690  36.442 < 2e-16 ***
fri[-1]                 31.377099  0.915053  34.290 < 2e-16 ***
sat[-1]                 34.748895  0.893023  38.912 < 2e-16 ***
sun[-1]                 49.607578  0.936075  52.995 < 2e-16 ***
BOCHUM_TOTAL[-1]         3.409286  1.827480   1.866 0.062234 .
KEMNADE_IN_FLAMMER[-1]   3.866158  1.844238   2.096 0.036165 *
holiday[-1]             20.600866  1.087712  18.940 < 2e-16 ***
covid[-1]              -1.532874  0.609395  -2.515 0.011960 *
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.099 on 2212 degrees of freedom
Multiple R-squared:  0.9532,    Adjusted R-squared:  0.9529

```

- Heilt Autokorr auf Lag 1
- Was passiert bei den übrigen Lags?

```
> #Durbin-Watson-Test
> dwtest(reg_final_extended) #H0: keine Autokorrelation.

Durbin-Watson test


data: reg_final_extended
DW = 2.0188, p-value = 0.6505
alternative hypothesis: true autocorrelation is greater than 0

> dwtest(reg_final)


Durbin-Watson test

data: reg_final
DW = 1.8607, p-value = 0.0004232
alternative hypothesis:
```

Series coredata(residuals(reg_final))



Series coredata(residuals(reg_final_extended))



- Ausführen von Zeilen 173-179
- Wegen Hetero Wechsel auf White SE
- Was ändert sich?
- Zugehörige Nachbetrachtung in einem Satz folgt

```
> coeftest(reg_final_extended)

t test of coefficients:


```

	Estimate	Std. Error	t value	Pr(> t)	
AMOUNT[-length(AMOUNT)]	0.07574490	0.01973236	3.8386	0.0001272	***
daycounter[-1]	-0.00175227	0.00034601	-5.0643	4.438e-07	***
mon[-1]	31.31092828	1.18989743	26.3140	< 2.2e-16	***
tue[-1]	30.82972087	0.90929183	33.9052	< 2.2e-16	***
wed[-1]	31.76097715	0.87664587	36.2301	< 2.2e-16	***
thu[-1]	32.53167289	0.89268998	36.4423	< 2.2e-16	***
fri[-1]	31.37709856	0.91505329	34.2899	< 2.2e-16	***
sat[-1]	34.74889535	0.89302352	38.9115	< 2.2e-16	***
sun[-1]	49.60757761	0.93607478	52.9953	< 2.2e-16	***
BOCHUM_TOTAL[-1]	3.40928576	1.82748024	1.8656	0.0622343	.
KEMNADE_IN_FLAMMER[-1]	3.86615827	1.84423783	2.0963	0.0361650	*
holiday[-1]	20.60086591	1.08771244	18.9396	< 2.2e-16	***
covid[-1]	-1.53287446	0.60939466	-2.5154	0.0119599	*

```

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> coeftest(reg_final_extended,vcov = vcovHC(reg_final_extended, type = "HC0"))#white estimator

t test of coefficients:


```

	Estimate	Std. Error	t value	Pr(> t)	
AMOUNT[-length(AMOUNT)]	0.07574490	0.02027224	3.7364	0.0001914	***
daycounter[-1]	-0.00175227	0.00034025	-5.1500	2.836e-07	***
mon[-1]	31.31092828	1.32663338	23.6018	< 2.2e-16	***
tue[-1]	30.82972087	0.96519626	31.9414	< 2.2e-16	***
wed[-1]	31.76097715	0.81417643	39.0099	< 2.2e-16	***
thu[-1]	32.53167289	0.89661794	36.2826	< 2.2e-16	***
fri[-1]	31.37709856	0.89482424	35.0651	< 2.2e-16	***
sat[-1]	34.74889535	0.87619083	39.6590	< 2.2e-16	***
sun[-1]	49.60757761	1.00588341	49.3174	< 2.2e-16	***
BOCHUM_TOTAL[-1]	3.40928576	1.84807900	1.8448	0.0652042	.
KEMNADE_IN_FLAMMER[-1]	3.86615827	2.14673533	1.8009	0.0718473	.
holiday[-1]	20.60086591	3.28954279	6.2625	4.537e-10	***
covid[-1]	-1.53287446	0.59529023	-2.5750	0.0100883	*

Fallstudie

- Es sei $y_t = a + by_{t-1} + e_t$.
- Dann $Cov[x, e] = Cov[y_{t-1}, e_t] = Cov[y_{t-1}, y_t - a - by_{t-1}] = -bVar[Y_{t-1}] \neq 0$
- Man beachte, dass $Cov[y_{t-1}, e_t] \neq 0$
- Aber solange $Cov[x_t, e_t] = 0$ gilt, können wir dennoch fast wie gewohnt verfahren
- „This means that x_s is allowed to depend upon e_t as long as $s \neq t$. The inclusion of a lagged dependent variable is the most important example of such a situation“ (Verbeek, 2012, 139)
- „The lagged dependent variable is then said to be predetermined with respect to the error term e_t “ [...] y_{t-1} „realized value has no impact on the error term“ e_t (Davidson & MacKinnon, 2009, 91)
- Voraussetzungen sind:
 - $Var[e_i] = \sigma^2$ (Homoskedastizität)
 - $Cov[e_i, e_j] = 0, i \neq j$ (Keine Autokorrelation im Störterm)
- **THEN*** „the OLS estimator is consistent and asymptotically efficient“
- **Liegt Heteroskedastizität vor, so muss mit White SE gearbeitet werden!**
- Autokorrelation hingegen ist nicht durch HAC heilbar!!! (*Verbeek, 2017, 141-142)

Fallstudie CAPM incl. GARCH

Motivation

Wir nutzen das CAPM Bsp aus Verbeek noch einmal (Coding GML_04_04 capm.R)

Zur Erinnerung:


```
> coeftest(reg)
t test of coefficients:

              Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.072585   0.115424  -0.6289   0.5297
X             1.168168   0.025485  45.8372  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> #vs
> coeftest(reg,vcov=NeweyWest(reg))#now use heteroskedasticity and autocorrelation
t test of coefficients:

              Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.072585   0.115715  -0.6273   0.5307
X             1.168168   0.034186  34.1706  <2e-16 ***
```

Was fällt auf?



CAPM incl. GARCH

Motivation

Wir schätzen das CAPM Bsp aus Verbeek mit einem GARCH Störterm

Schätzmethode?

Interpretieren Sie!




Was ist noch zu tun?

```
> #compare and note that beta is now slightly higher than in ordinary OLS
> coefficients(reg)
(Intercept)          X
-0.07258514  1.16816828
> coef(garch2)
      mu      mxreg1      alpha1      beta1      omega
-0.13517992  1.19623684  0.07863434  0.89519493  0.21049951
```

Motivation

Wir schätzen das CAPM Bsp aus Verbeek mit einem GARCH Störterm, ACF bis Lag 20 (x-Achse ist verwirrend)

Interpretieren Sie!



ARIMA & GARCH

Nachbereitung

Arbeiten Sie Ch. 8 in Verbeek (2017) und
Kap. 11 in Gehrke (2022) nach.